

MAT-266: Diagnóstico de influencia en regresión lineal

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Diagnóstico de influencia en regresión lineal

Suponga que se desea evaluar el efecto de eliminar una observación sobre la estimación de β . En este caso, podemos considerar el **modelo de datos eliminados**

$$\mathbf{Y}_{(i)} = \mathbf{X}_{(i)}\beta + \epsilon_{(i)}, \quad (1)$$

de ahí que

$$\hat{\beta}_{(i)} = (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{Y}_{(i)}.$$

Considere

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{(i)}^\top \\ \mathbf{x}_i^\top \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} \mathbf{Y}_{(i)}^\top \\ Y_i \end{pmatrix},$$

de ahí que

$$\mathbf{X}^\top \mathbf{X} = (\mathbf{X}_{(i)}^\top, \mathbf{x}_i) \begin{pmatrix} \mathbf{X}_{(i)}^\top \\ \mathbf{x}_i^\top \end{pmatrix} = \mathbf{X}_{(i)}^\top \mathbf{X}_{(i)} + \mathbf{x}_i \mathbf{x}_i^\top,$$

$$\mathbf{X}^\top \mathbf{Y} = (\mathbf{X}_{(i)}^\top, \mathbf{x}_i) \begin{pmatrix} \mathbf{Y}_{(i)}^\top \\ Y_i \end{pmatrix} = \mathbf{X}_{(i)}^\top \mathbf{Y}_{(i)} + \mathbf{x}_i Y_i.$$



Diagnóstico de influencia en regresión lineal

Reagrupando, podemos escribir

$$\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)} = \mathbf{X}^\top \mathbf{X} (\mathbf{I} - (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top),$$

cuya matriz inversa es dada por

$$\begin{aligned} (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} &= (\mathbf{I} - (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top)^{-1} (\mathbf{X}^\top \mathbf{X})^{-1} \\ &= \left\{ \mathbf{I} + \frac{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top}{1 - \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i} \right\} (\mathbf{X}^\top \mathbf{X})^{-1}. \end{aligned}$$

De este modo,

$$\begin{aligned} \hat{\beta}_{(i)} &= (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{Y}_{(i)} \\ &= \left\{ \mathbf{I} + \frac{1}{1 - h_{ii}} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top \right\} (\mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{X}^\top \mathbf{Y} - \mathbf{x}_i Y_i) \\ &= \left\{ \mathbf{I} + \frac{1}{1 - h_{ii}} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top \right\} (\hat{\beta} - (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i Y_i) \\ &= \hat{\beta} - \frac{e_i}{1 - h_{ii}} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i. \end{aligned}$$



Observación:

Una característica importante de la ecuación anterior es que depende solamente de cálculos obtenidos desde el [modelo con datos completos](#).

Sea

$$e_{j(i)} = Y_j - \hat{Y}_{j(i)} = Y_j - \mathbf{x}_j^\top \hat{\boldsymbol{\beta}}_{(i)},$$

el j -ésimo residuo con la i -ésima observación eliminada, en particular

$$\begin{aligned} e_{i(i)} &= Y_i - \hat{Y}_{i(i)} = Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{(i)} = Y_i - \mathbf{x}_i^\top \left(\hat{\boldsymbol{\beta}} - \frac{e_i}{1 - h_{ii}} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \right) \\ &= e_i + \frac{e_i h_{ii}}{1 - h_{ii}} = \frac{e_i}{1 - h_{ii}}, \end{aligned}$$

es conocido como [residuo eliminado](#).



Diagnóstico de influencia en regresión lineal

Note además que

$$\begin{aligned}\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)} &= \mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\left(\hat{\boldsymbol{\beta}} - \frac{e_i}{1 - h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i\right) \\ &= \frac{e_i}{1 - h_{ii}} \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i.\end{aligned}$$

Por otro lado,

$$\begin{aligned}(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)})^\top (\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)}) &= \left(\frac{e_i}{1 - h_{ii}}\right)^2 \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \\ &= h_{ii} \left(\frac{e_i}{1 - h_{ii}}\right)^2,\end{aligned}$$

es decir esta medida del efecto de remover la i -ésima observación sobre la predicción depende sólo de e_i y h_{ii} .



Diagnóstico de influencia en regresión lineal

Podemos evaluar el efecto de la i -ésima observación sobre el estimador de σ^2 podemos considerar el estimador $s_{(i)}^2$. En efecto,

$$\text{RSS}_{(i)} = \sum_{j \neq i} (Y_j - \mathbf{x}_j^\top \hat{\boldsymbol{\beta}}_{(i)})^2 = \text{RSS} - \frac{e_i^2}{1 - h_{ii}}.$$

De ahí que

$$s_{(i)}^2 = \frac{1}{n - p - 1} \left\{ (n - p) s^2 - \frac{e_i^2}{1 - h_{ii}} \right\}$$



Resultado 1:

Considere el [modelo de salto en la media](#):

$$Y = X\beta + d_i\gamma + \epsilon, \quad (2)$$

con $\epsilon \sim N(0, \sigma^2 I)$ y $d_i = (0, 1, 0)^\top$ un vector de ceros con un 1 en la i -ésima posición. De este modo, el estimador ML de β en el modelo (1) y (2) coinciden.

Demostración:

El resultado sigue mediante escribir el modelo en (2) como

$$Y = Z\theta + \epsilon, \quad Z = (X, d_i), \quad \theta = (\beta^\top, \gamma)^\top,$$

y $\hat{\theta} = (Z^\top Z)^{-1} Z^\top Y$. Tenemos que

$$Z^\top Z = \begin{pmatrix} X^\top \\ d_i^\top \end{pmatrix} (X, d_i) = \begin{pmatrix} X^\top X & X^\top d_i \\ d_i^\top X & d_i^\top d_i \end{pmatrix} = \begin{pmatrix} X^\top X & x_i \\ x_i^\top & 1 \end{pmatrix},$$

$$Z^\top Y = \begin{pmatrix} X^\top \\ d_i^\top \end{pmatrix} Y = \begin{pmatrix} X^\top Y \\ Y_i \end{pmatrix}.$$



Diagnóstico de influencia en regresión lineal

Sabemos que

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \begin{pmatrix} (\mathbf{X}^\top \mathbf{X})^{-1} + \frac{1}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} & -\frac{1}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \\ -\frac{1}{1-h_{ii}} \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} & \frac{1}{1-h_{ii}} \end{pmatrix},$$


luego

$$\begin{aligned} \hat{\beta}_* &= \left\{ (\mathbf{X}^\top \mathbf{X})^{-1} + \frac{1}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \right\} \mathbf{X}^\top \mathbf{Y} - \frac{Y_i}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \\ &= \left\{ \mathbf{I} + \frac{1}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^\top \right\} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} - \frac{Y_i}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \\ &= \hat{\beta} + \frac{\hat{Y}_i}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i - \frac{Y_i}{1-h_{ii}}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i = \hat{\beta}_{(i)}. \end{aligned}$$



Cuarteto de regresiones “idénticas” de Anscombe (1973)

Anscombe's 4 Regression data sets



Diagnóstico de influencia en regresión lineal

Basado en el elipsoide de confianza del $100(1 - \alpha)\%$ para β ,

$$\frac{(\beta - \hat{\beta})^\top \mathbf{X}^\top \mathbf{X} (\beta - \hat{\beta})}{ps^2} \leq F_{p, n-p}(1 - \alpha).$$

Cook (1977)¹ propuso **determinar la influencia** de la i -ésima observación, usando

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta}_{(i)} - \hat{\beta})}{ps^2} = \frac{r_i^2}{p} \left(\frac{h_i}{1 - h_i} \right),$$

para $i = 1, \dots, n$, y recomendó comparar D_i con algún percentil de la distribución $F_{p, n-p}$ ($\alpha = 0.10$). Otra alternativa más razonable puede ser usar $\alpha = 0.50$, y se ha sugerido que $D_i > 1$ es un **indicador de observaciones influyentes**.

¹Technometrics 19, 15-18



Diagnóstico de influencia en regresión lineal

Welsch y Kuh (1977)² propusieron medir el impacto en la i -ésima observación sobre el valor predicho como

$$\text{DFFIT}_i = \hat{Y}_i - \hat{Y}_{i(i)} = \mathbf{x}_i^\top (\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)}) = \frac{h_{ii}e_i}{1 - h_{ii}},$$

y su versión estandarizada

$$\begin{aligned}\text{DFFITS}_i &= \frac{\hat{Y}_i - \hat{Y}_{i(i)}}{s_{(i)}\sqrt{h_{ii}}} = \left(\frac{h_{ii}}{1 - h_{ii}}\right)^{1/2} \frac{e_i}{s_{(i)}\sqrt{1 - h_{ii}}} \\ &= \left(\frac{h_{ii}}{1 - h_{ii}}\right)^{1/2} t_i\end{aligned}$$

Belsley, Kuh y Welsch (1980)³ sugieren poner especial atención en aquellos casos donde $\text{DFFITS}_i > 2\sqrt{p/n}$.

Observación:

En ocasiones esta medida es conocida como **distancia Welsch-Kuh**.

²Working paper No. 173, National Bureau of Economics, Cambridge

³Regression Diagnostics. Wiley, New York



Diagnóstico de influencia en regresión lineal

Atkinson (1981)⁴ sugirió usar una versión modificada de la distancia de Cook, como

$$\begin{aligned} AK_i &= \sqrt{\left(\frac{n-p}{p}\right)\left(\frac{h_{ii}}{1-h_{ii}}\right)} \left| \frac{e_i}{s_{(i)}\sqrt{1-h_{ii}}} \right| \\ &= \sqrt{\left(\frac{n-p}{p}\right)\left(\frac{h_{ii}}{1-h_{ii}}\right)} |t_i| \\ &= \sqrt{\frac{n-p}{p}} |DFFITS_i|. \end{aligned}$$

Cuando $h_{ii} = p/n, \forall i$, tenemos $AK_i = |t_i|$ debido a esto se recomienda hacer el gráfico de AK_i vs. $|t_i|$. Además podemos identificar la i -ésima observación como influyente si $AK_i > 2$.

Observación:

AK_i puede considerarse como una medida de influencia conjunta sobre $\hat{\beta}$ y s^2 simultáneamente.

⁴Biometrika 68, 13-20



Diagnóstico de influencia en regresión lineal

Cook y Weisberg (1980)⁵ propusieron considerar medidas generales de influencia⁶ considerando,

$$D_i(\mathbf{M}, c) = \frac{(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})^\top \mathbf{M} (\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})}{c},$$

donde \mathbf{M} es matriz definida positiva $p \times p$ y $c > 0$ es un factor de escala.

Algunas medidas de influencia:

\mathbf{M}	c	Medida	Referencia
$\mathbf{X}^\top \mathbf{X}$	ps^2	D_i	Cook (1977)
$\mathbf{X}^\top \mathbf{X}$	$ps_{(i)}^2$	$(DFFITs_i)^2$	Welsch y Kuh (1977)
$\mathbf{X}^\top \mathbf{X}$	$(n-1)^2 ps_{(i)}^2 / (n-p)$	AK_i	Atkinson (1981)


⁵Technometrics 22, 495-508

⁶Basadas en la función de influencia empírica.



Distancia de Cook: Datos de Anscombe (1973)

Cook's distance plots. Anscombe's data sets



Diagnóstico de influencia en regresión lineal

Considere comparar $\text{Cov}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ con la **matriz de covarianza que resulta de eliminar el i -ésimo caso**. Esto lleva a (Belsley, Kuh y Welsch, 1980)

$$\begin{aligned} COVRATIO_i &= \frac{\det\{s_{(i)}^2(\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1}\}}{\det\{s^2(\mathbf{X}^\top \mathbf{X})^{-1}\}} = \left(\frac{s_{(i)}^2}{s^2}\right)^p \frac{\det(\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1}}{\det(\mathbf{X}^\top \mathbf{X})^{-1}} \\ &= \frac{1}{1 - h_i} \left(\frac{n - p - r_i^2}{n - p - 1}\right)^p, \end{aligned}$$

se ha planteado como punto de corte $|COVRATIO_i - 1| > 3p/n$.



Diagnóstico de influencia en regresión lineal

Existe un **repertorio bastante extenso de medidas de influencia**, por ejemplo:

Medida	Punto de corte
$D_i = \frac{r_i^2}{p} \left(\frac{h_i}{1-h_i} \right)$	$F_{p, n-p}(1-\alpha)$
$DFFITS_i = t_i \sqrt{\frac{h_i}{1-h_i}}$	$2\sqrt{p/n}$
$AK_i = DFFITS_i \sqrt{\frac{n-p}{p}}$	$2\sqrt{(n-p)/n}$
$W_i = DFFITS_i \sqrt{\frac{n-1}{1-h_i}}$	$3\sqrt{p}$
$COVRATIO_i = \frac{1}{1-h_i} \left(\frac{n-p-r_i^2}{n-p-1} \right)^p$	$ COVRATIO_i - 1 > 3p/n$
$h_i = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i$	$2p/n$
$r_i = \frac{e_i}{s\sqrt{1-h_i}}$	$\approx N(0, 1)$
$t_i = r_i \sqrt{\frac{n-p-1}{n-p-r_i^2}}$	$\approx t(n-p-1)$



Belsley, Kuh y Welsch (1981) y Velleman y Welsch (1981)⁷ han discutido **estrategias para amenizar el cálculo** de estas medidas de influencia.

Para modelos de regresión lineal algunas de estas medidas han sido **implementadas en software estadístico** tal como SAS, SPSS, S-PLUS/R.

En particular, R (o S-PLUS) disponen de las funciones **lm.influence** y **ls.diag** asociadas con las funciones **lm** (o **glm**) y **lsfit**, respectivamente.

La función **lm.influence** dispone de las siguientes medidas:


rstandard	rstudent	dffits	dfbetas
covratio	cooks.distance	hatvalues	

Estas cantidades **pueden ser escritas de forma eficiente** usando la descomposición QR o SVD.

⁷The American Statistician 35, 234-242.



Influencia de múltiples casos



Sea $I = (i_1, \dots, i_m)^\top$ vector de índices m -dimensional, tal que $1 \leq i_j \leq m$. La distancia de Cook adopta la forma:

$$D_I(\mathbf{M}, c) = \frac{(\hat{\beta} - \hat{\beta}_{(I)})^\top \mathbf{M} (\hat{\beta} - \hat{\beta}_{(I)})}{c}.$$

Usando que

$$\hat{\beta}_{(I)} = \hat{\beta} - (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}_I^\top (\mathbf{I} - \mathbf{H}_I)^{-1} \mathbf{e}_I,$$

lleva a una fórmula más conveniente para la **distancia de Cook**, D_I

$$D_I = \frac{\mathbf{e}_I^\top (\mathbf{I} - \mathbf{H}_I)^{-1} \mathbf{H}_I (\mathbf{I} - \mathbf{H}_I)^{-1} \mathbf{e}_I}{ps^2}.$$

Observación:

D_I puede ser evaluado en $\binom{n}{m}$ posibles subconjuntos de casos.



Múltiples datos atípicos pueden ser detectados mediante el modelo

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{D}_m\boldsymbol{\phi} + \boldsymbol{\epsilon},$$

donde $\mathbf{D}_m \in \mathbb{R}^{n \times m}$ cuya i -ésima columna es \mathbf{d}_{i_k} y $\boldsymbol{\phi}$ es vector m -dimensional. La hipótesis $H : \boldsymbol{\phi} = \mathbf{0}$ lleva al estadístico

$$t_I^2 = \left(\frac{n - p - m}{m} \right) \frac{\mathbf{e}_I^T (\mathbf{I} - \mathbf{H}_I)^{-1} \mathbf{e}_I}{(n - p)s^2 - \mathbf{e}_I^T (\mathbf{I} - \mathbf{H}_I)^{-1} \mathbf{e}_I},$$

con distribución nula (bajo normalidad) dada por $F(m, n - p - m)$.



- ▶ Lamentablemente este problema tiene un **costo computacional muy alto**.
- ▶ Típicamente las técnicas de eliminación de **un único caso no son suficiente**.
- ▶ Técnicas para multiples casos pueden sufrir del **efecto de enmascaramiento**.



Outliers y su relación con el problema de colinealidad:

- ▶ Propuestas para **robustificar** el estimador ridge
(Holland, 1973; Askin y Montgomery, 1980; Lawrence y Marsh, 1984 y Silvapulle, 1991).
- ▶ **Diagnóstico de influencia** en regresión ridge
(Steece, 1986; Walker y Birch, 1988; Billor y Loynes, 1999; Shi y Wang, 1999 y Labra, Aoki y Rojas, 2007).
- ▶ Colinealidad **inducida** por outliers
(Mason y Gunst, 1985; Hadi, 1988 y Walker, 1989).



Walker y Birch (1988)⁸, propusieron las siguientes medidas de diagnóstico:

- Leverage:

$$H(k) = \mathbf{X}(\mathbf{X}^\top \mathbf{X} + k\mathbf{I})^{-1} \mathbf{X}^\top.$$

- Distancia de Cook:

$$D_i^* = \frac{(\hat{\beta}_k - \hat{\beta}_k(i))^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta}_k - \hat{\beta}_k(i))}{ps^2},$$

$$D_i^{**} = \frac{(\hat{\beta}_k - \hat{\beta}_k(i))^\top (\mathbf{X}^\top \mathbf{X} + k\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X} + k\mathbf{I})^{-1} (\hat{\beta}_k - \hat{\beta}_k(i))}{ps^2},$$

para $i = 1, \dots, n$.

⁸Technometrics 30, 221-227.

Outliers que inducen colinealidad

Hadi (1988)⁹ y Walker (1989)¹⁰, proponen detectar observaciones que inducen o ocultan colinealidad, mediante:

$$\gamma_i = \frac{\kappa_{(i)} - \kappa}{\kappa}, \quad i = 1, \dots, n,$$

donde $\kappa_{(i)} = \kappa(\mathbf{X}_{(i)})$ y $\kappa = \kappa(\mathbf{X})$.

Concluyeron que:

Aquellas observaciones que **afectan** el condicionamiento de \mathbf{X} frecuentemente tienen **alto leverage**.

⁹Computational Statistics & Data Analysis 7, 143-159

¹⁰Communications in Statistics: Theory and Methods 18, 1675-1690.



Cemento Portland (Woods, Steinour y Starke, 1932)

Ejemplo (Datos de cemento Portland):

Estudio experimental relacionando la emisión de calor durante la producción y endurecimiento de 13 muestras de cementos Portland. Woods, Steinour y Starke (1932) consideraron cuatro compuestos para los clinkers desde los que se produce el cemento.

La respuesta (Y) es la **emisión de calor** después de 180 días de curado, medido en calorías por gramo de cemento. Los regresores son los porcentajes de los cuatro compuestos principales: **aluminato tricálcico** (X_1), **silicato tricálcico** (X_2), **ferrito aluminato tetracálcico** (X_3) y **silicato dicálcico** (X_4).



Cemento Portland (Woods, Steinour y Starke, 1932)

Siguiendo a Woods, Steinour y Starke (1932) consideramos un modelo lineal **sin intercepto (modelo homogéneo)**, cuyo número condición escalado es $\kappa(\mathbf{X}) = 9.432$, esto es, \mathbf{X} es bien condicionada (variables centradas $\kappa(\widetilde{\mathbf{X}}) = 37.106$).



Por otro lado, Hald (1952), Gorman y Toman (1966) y Daniel y Wood (1980) adoptan un modelo **con intercepto (modelo no homogéneo)**. En cuyo caso $\kappa(\mathbf{X}) = 249.578$, sugiriendo la presencia de colinealidad. El aumento en el número condición se debe a que existe una relación lineal aproximada, pues

$$x_1 + x_2 + x_3 + x_4 \approx 100,$$

de modo que incluir el intercepto causa una colinealidad severa.





Distancia de Cook:




Estimación mínimos cuadrados: Modelo homogéneo (a) y no homogéneo (b).

Distancia de Cook:




Estimación ridge: D_i^* (c) y D_i^{**} (d).

Leverage:



Modelo homogéneo (a), modelo no homogéneo (b) y ridge (c).

Número condición relativo: $\gamma_i = (\kappa_{(i)} - \kappa) / \kappa$



Es decir, *obs. 3* afecta el condicionamiento de \mathbf{X} . En efecto, $\kappa(\mathbf{X}_{(3)}) = 343.658$ mientras que, $\kappa(\mathbf{X}) = 249.578$ (oculta una colinealidad).