

IECD-325: Modelos lineales y diseños de experimentos

Felipe Osorio

`felipe.osorio@uv.cl`

Horario:

Clases: MA 08:30-10:00 hrs Sala 3, MI 08:30-10:00 hrs Lab. Computación,
JU 12:00-13:30 y 14:30-16:00 hrs Sala 3.

Contacto:

E-mail: felipe.osorio@uv.cl.

Web: <https://github.com/faosorios/Curso-Regresion> y **AULA**

Evaluación:

Se realizará **3 Pruebas**: 4-Sep, 30-Oct, 4-Dic. **Exámen**: 11-Dic.

Criterio de aprobación

Criterio de aprobación:

Considere NP como la **nota de presentación**, a saber:

$$NP = 0.25 \cdot P_1 + 0.25 \cdot P_2 + 0.25 \cdot P_3 + T_*,$$

donde P_1 , P_2 y P_3 representan las notas en las **pruebas** 1, 2 y 3, mientras que T_* representa el **promedio ponderado de tareas**, es decir:

$$T_* = 0.08 \cdot T_1 + 0.08 \cdot T_2 + 0.09 \cdot T_3.$$

Aquellos estudiantes que obtengan **NP mayor o igual a 50**, aprobarán la asignatura con nota final, $NF = NP$.

Criterio para rendir el Exámen:

En caso contrario, los estudiantes podrán rendir el **Examen**. En cuyo caso, la **nota final** es calculada como sigue:

$$NF = 0.7 \cdot NP + 0.3 \cdot Examen.$$

Reglas adicionales

- ▶ Se llevará un **control de asistencia**.
- ▶ Se puede realizar **preguntas** sobre la materia en **cualquier momento**.
- ▶ Los alumnos deben **apagar/silenciar** su **celular** durante clases.
- ▶ Conversaciones sobre asuntos ajenos a la clase no serán tolerados. Otros estudiantes tiene derecho a **asistir clases en silencio**.
- ▶ Alumnos que lleguen tarde o se retiren deben hacerlo en **silencio**.
- ▶ Al enviar algún **e-mail al profesor**, identificar el código de la asignatura en el asunto (**IECD325**).
- ▶ **E-mail** será el canal de **comunicación oficial** entre el profesor y los estudiantes.

Reglas: sobre los certámenes

- ▶ Todas las **hojas necesarias** para responder las pruebas **serán entregadas por el profesor**.
- ▶ Será permitido el uso de una **calculadora científica simple** (no del celular).
- ▶ Es derecho del estudiante conocer la **pauta de corrección** la que será publicada **en la página web del curso**.
- ▶ Use principalmente **lápiz pasta** (no utilice lápiz rojo).
- ▶ Pedidos de corrección **deben ser argumentados por escrito**.
- ▶ **Cualquier tipo de fraude** en prueba (copia, uso de WhatsApp, suplantación, etc.) será sancionado.

Orientaciones de estudio

- ▶ Mantener la frecuencia de estudio de inicio a final del semestre. El ideal es estudiar el contenido luego de cada clase.
- ▶ Estudiar primeramente el contenido dado en clases, buscando apoyo en las referencias bibliográficas.
- ▶ Las referencias son fuentes de ejemplos y ejercicios. Resuelva una buena cantidad de ejercicios. No deje esto para la víspera de la prueba.
- ▶ Buscar las referencias bibliográficas al inicio del semestre, dando preferencia a las principales y complementarias.

Prerrequisitos

- ▶ Los requisitos formales son:
 - ▶ IECD-312: Inferencia.
 - ▶ IECD-315: Distribución de formas cuadráticas.
- ▶ Se asume un conocimiento básico de los siguientes aspectos:
 - ▶ Variables aleatorias.
 - ▶ Convergencia de variables aleatorias.
 - ▶ Manipulación de matrices y vectores aleatorios.

1. Modelos de regresión lineal simple.
2. Inferencia en el modelo de regresión lineal múltiple.
3. Análisis de los supuestos del modelo.
4. Alternativas a mínimos cuadrados.
5. Modelos de diseños de experimentos.
6. Tópicos adicionales.

¹Este es un curso **fundamental** donde exploramos métodos para abordar la inferencia en modelos de regresión, **no** es un curso enfocado **solamente** en el análisis de datos.

Bibliografía



Belsley, D.A., Kuh, E., Welsch, R.E. (1984).

Regression Diagnostics: Identifying Influential Data and Sources of Collinearity.
Wiley, New York.



Kutner, M.H., Nachtsheim, C.J., Neter, J., Li, W. (2005).

Applied Linear Statistical Models, 5th Ed.
McGraw-Hill, Boston.



Montgomery, D.C. (2004).

Diseño y Análisis de Experimentos, 2da Ed.
Limusa, México DF.



Seber, G.A.F., Lee, A.J. (2007).

Linear Regression Analysis, 2nd Ed.
Wiley, New York.

Bibliografía adicional



Hocking, R. (2013).

Methods and Applications of Linear Models: Regression and the analysis of variance, 3rd Ed.

Wiley, New York.



Rencher, A.C., Schaalje, G.B. (2007).

Linear Models in Statistics, 2nd Ed.

Wiley, New York.



Sheather, S.J. (2009).

A Modern Approach to Regression with R.

Springer, New York.




Weisberg, S. (2013).

Applied Linear Regression, 4th Ed.

Wiley, New York.

Objetivo del análisis de regresión

Estudiar una variable de **respuesta**, y [asumiendo continua] como función de algunas variables explicativas o **regresores**, x_1, x_2, \dots [pueden ser discretas y/o continuas].



En ocasiones la relación funcional es **conocida** salvo algunos coeficientes (**parámetros**).

Es decir, la relación es gobernada por un **proceso físico** o por leyes bien aceptadas

$$Y \approx f(x_1, \dots, x_p; \theta),$$

en cuyo caso, el interés recae en **estimar el vector de parámetros** $\theta = (\theta_1, \dots, \theta_p)^\top$.

Asumiremos variables aleatorias independientes Y_1, \dots, Y_n , tal que

$$Y_i = \mu_i + \epsilon_i, \quad E(\epsilon_i) = 0, \quad i = 1, \dots, n,$$

esto es,

respuesta = parte sistemática + error aleatorio

Idea:


Se desea “estructurar” la función de medias como

$$\mu_i = \mu_i(\boldsymbol{\beta}), \quad i = 1, \dots, n,$$

con $\boldsymbol{\beta} \in \mathbb{R}^p$ y $n \gg p$.

Datos de Forbes (1857)²

Presión barométrica en pulgadas de mercurio y temperatura de ebullición del agua en grados Fahrenheit para 17 diferentes altitudes.



²Transactions of the Royal Society of Edinburgh **21**, 235-243.

Para describir la relación entre la temperatura y la media de la presión barométrica, podemos considerar

$$\mu = \beta_0 + \beta_1 x,$$

note que

$$\mu = \mathbf{x}^\top \boldsymbol{\beta}, \quad \mathbf{x} = (1, x)^\top, \quad \boldsymbol{\beta} = (\beta_0, \beta_1)^\top,$$

y $\mathbf{x}^\top \boldsymbol{\beta}$ se denomina **predictor lineal**.

El conjunto de datos consiste del **vector de respuestas**.

$$\mathbf{Y} = (Y_1, \dots, Y_n)^\top,$$

y una **matriz de diseño** $n \times 2$

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix}.$$

Convención:

Todos los vectores siempre serán **columna**.

Considere el modelo

$$\text{Presión}_i = \beta_0 + \beta_1 \text{Temperatura}_i + \epsilon_i,$$

para $i = 1, \dots, 17$.

En nuestro caso (usando función `lm` de \mathbf{R}^3), obtuvimos:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\hat{\beta}_0, \hat{\beta}_1)^\top = (-81.0637, 0.5229)^\top \\ s^2 &= \frac{1}{17-2} \sum_{i=1}^n (\text{Presión}_i - \hat{\beta}_0 - \hat{\beta}_1 \text{Temperatura}_i)^2 \\ &= 0.0542.\end{aligned}$$


Además, $R^2 = \text{cor}^2(\text{Presión}, \hat{\text{Presión}}) = 0.9944$, donde

$$\hat{\text{Presión}}_i = \hat{\beta}_0 + \hat{\beta}_1 \text{Temperatura}_i, \quad i = 1, \dots, 17.$$


³R puede ser descargado desde CRAN: <https://cran.r-project.org/>

⁴Datos disponibles en la biblioteca `alr4` para R.

Datos de Forbes



(a) recta ajustada



(b) residuos vs. ajuste

Ahora consideramos el modelo

$$100 \times \log_{10}(\text{Presión}_i) = \beta_0 + \beta_1 \text{Temperatura}_i + \epsilon_i,$$

para $i = 1, \dots, 17$.


Se obtuvo:

$$\hat{\beta} = (-42.1378, 0.8955)^\top \quad \text{y} \quad s^2 = 0.1438$$


Además, $R^2 = 0.9950$.

Datos de Forbes

Recta de regresión y gráfico de residuos para los datos de Forbes⁵.



(a) recta ajustada



(b) residuos vs. ajuste

⁵datos transformados

Datos de Huber (1981)⁶


Considere el conjunto de **datos hipotéticos** de Huber.

Y	2.48	0.73	-0.04	-1.44	-1.32	0.00
x	-4	-3	-2	-1	0	10


⁶*Robust Statistics*. Wiley, New York

Datos de Huber


Diagrama de dispersión para los datos de Huber.




¿Qué opina de la recta de regresión?



¿Y ahora?




¿Cuál modelo prefiere?



Datos de Concha y Toro (Osorio y Galea, 2006)⁷

Rentabilidades mensuales de Concha y Toro vs. IPSA, ajustados por bonos de interés del Banco Central entre marzo/1990 a abril/1999.



⁷Statistical Papers 47, 31-38

Modelo CAPM (Valoración de Activos de Capital), Sharpe (1964)⁸

$$E(r) = r_f + \beta(E(r_m) - r_f),$$

usando datos observados, podemos escribir

$$R_t = \alpha + \beta \times IPSA_t + \epsilon, \quad t = 1, \dots, T.$$

Características del problema:


- ▶ Relación **lineal** entre las variables.
- ▶ Posibles periodos de **alta volatilidad**.

Hipótesis de interés:

- ▶ $H_0 : \beta > 1$ (**Amante del riesgo**).
- ▶ $H_0 : \beta = 1$ (**Neutral al riesgo**).
- ▶ $H_0 : \beta < 1$ (**Averso al riesgo**).

⁸Journal of Finance **19**, 425-442

Datos de Concha y Toro



Ajuste usando errores **normales** (—) y **Cauchy** (--).

Cemento Portland (Woods, Steinour y Starke, 1932)⁹

Estudio experimental relacionando la emisión de calor durante la producción y endurecimiento de 13 muestras de cementos Portland. Woods et al. (1932) consideraron cuatro compuestos para los clinkers desde los que se produce el cemento.

La respuesta (Y) es la emisión de calor después de 180 días de curado, medido en calorías por gramo de cemento. Los regresores son los porcentajes de los cuatro compuestos: aluminato tricálcico (X_1), silicato tricálcico (X_2), ferrito aluminato tetracálcico (X_3) y silicato dicálcico (X_4).

⁹Industrial and Engineering Chemistry 24, 1207-1214.

Cemento Portland (Woods, Steinour y Starke, 1932)

Y	x_1	x_2	x_3	x_4
78.5	7	26	6	60
74.3	1	29	15	52
104.3	11	56	8	20
87.6	11	31	8	47
95.9	7	52	6	33
109.2	11	55	9	22
102.7	3	71	17	6
72.5	1	31	22	44
93.1	2	54	18	22
115.9	21	47	4	26
83.8	1	40	23	34
113.3	11	66	9	12
109.4	10	68	8	12

Observación:

En efecto, existe una **relación lineal aproximada**, pues $x_1 + x_2 + x_3 + x_4 \approx 100$.

Datos de Puromycin (Treolar, 1974)

Modelo Michaelis-Menten: usado para el estudio de cinética de enzimas.

Permite estudiar la relación entre **velocidad inicial** de una reacción enzimática a la concentración de un substrato x a través de la ecuación:


$$f(x, \beta) = \frac{\beta_1 x}{\beta_2 + x}, \quad \beta = (\beta_1, \beta_2)^\top.$$

Diferenciando f con relación a β_1 y β_2 , obtenemos

$$\frac{\partial f}{\partial \beta_1} = \frac{x}{\beta_2 + x}, \quad \frac{\partial f}{\partial \beta_2} = -\frac{\beta_1 x}{(\beta_2 + x)^2}.$$


Datos de Puromycin

Velocidad de una reacción enzimática como función de la concentración del sustrato para un experimento sobre enzimas tratadas con **Puromycin**.



Datos de Puromycin


Velocidad de una reacción enzimática como función de la concentración del sustrato para un experimento sobre enzimas tratadas con **Puromycin**.




Modelos lineales son los *bloques de construcción* para metodologías más complejas, tales como:

- ▶ Modelos lineales generalizados.
- ▶ Modelos no lineales.
- ▶ Modelos de regresión espacial.
- ▶ Regresión multivariada.
- ▶ Datos longitudinales, GMANOVA.
- ▶ Regresión semiparamétrica.
- ▶ Modelos con efectos mixtos.


IECD-325: Modelos lineales y diseños de experimentos




(a) regresión LAD



(b) splines penalizados



(c) regresión no-lineal



(d) modelos mixtos