

IECD-325: Errores correlacionados y estimación de funciones de varianza

Felipe Osorio

felipe.osorio@uv.cl

Errores correlacionados

Considere el modelo

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon},$$

donde $E(\boldsymbol{\epsilon}) = \mathbf{0}$ y

$$\text{Cov}(\boldsymbol{\epsilon}) = E(\boldsymbol{\epsilon}\boldsymbol{\epsilon}^\top) = \sigma^2\boldsymbol{\Omega}, \quad \boldsymbol{\Omega} > \mathbf{0}.$$

Primeramente vamos a suponer que $\boldsymbol{\Omega}$ es conocida y sea

$$\boldsymbol{\Omega} = \mathbf{B}\mathbf{B}^\top,$$

con \mathbf{B} matriz no singular $n \times n$ y note que

$$\mathbf{B}^{-1}\mathbf{Y} = \mathbf{B}^{-1}\mathbf{X}\boldsymbol{\beta} + \mathbf{B}^{-1}\boldsymbol{\epsilon}.$$

haciendo $\mathbf{Y}_* = \mathbf{B}^{-1}\mathbf{Y}$, $\mathbf{X}_* = \mathbf{B}^{-1}\mathbf{X}$ y $\boldsymbol{\epsilon}_* = \mathbf{B}^{-1}\boldsymbol{\epsilon}$. Entonces $E(\boldsymbol{\epsilon}_*) = \mathbf{0}$, y

$$\text{Cov}(\boldsymbol{\epsilon}_*) = \mathbf{B}^{-1} \text{Cov}(\boldsymbol{\epsilon}) \mathbf{B}^{-\top} = \sigma^2 \mathbf{B}^{-1} \mathbf{B} \mathbf{B}^\top \mathbf{B}^{-\top} = \sigma^2 \mathbf{I}.$$

Errores correlacionados

Es decir, el modelo transformado

$$\mathbf{Y}_* = \mathbf{X}_* \boldsymbol{\beta} + \boldsymbol{\epsilon}_*,$$

satisface las condiciones A1-A4. Así,

$$\begin{aligned}\widehat{\boldsymbol{\beta}}_{\text{GLS}} &= (\mathbf{X}_*^\top \mathbf{X}_*)^{-1} \mathbf{X}_*^\top \mathbf{Y}_* \\ &= (\mathbf{X}^\top \mathbf{B}^{-\top} \mathbf{B}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{B}^{-\top} \mathbf{B}^{-1} \mathbf{Y} \\ &= (\mathbf{X}^\top (\mathbf{B} \mathbf{B}^\top)^{-1} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{B} \mathbf{B}^\top)^{-1} \mathbf{Y} \\ &= (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{Y}.\end{aligned}$$

Es fácil mostrar que

$$\begin{aligned}\mathbb{E}(\widehat{\boldsymbol{\beta}}_{\text{GLS}}) &= (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbb{E}(\mathbf{Y}) = \boldsymbol{\beta} \\ \text{Cov}(\widehat{\boldsymbol{\beta}}_{\text{GLS}}) &= \sigma^2 (\mathbf{X}_*^\top \mathbf{X}_*)^{-1} = \sigma^2 (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1}.\end{aligned}$$

Errores correlacionados

Además

$$\mathbf{e}_* = \mathbf{Y}_* = \mathbf{X}_* \hat{\boldsymbol{\beta}}_{\text{GLS}} = \mathbf{B}^{-1} \mathbf{Y} - \mathbf{B}^{-1} \mathbf{X} \hat{\boldsymbol{\beta}}_{\text{GLS}} = \mathbf{B}^{-1} (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}_{\text{GLS}}),$$

luego

$$\begin{aligned}\|\mathbf{e}_*\|^2 &= (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}_{\text{GLS}})^\top \mathbf{B}^{-\top} \mathbf{B}^{-1} (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}_{\text{GLS}}) \\ &= (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}_{\text{GLS}})^\top \boldsymbol{\Omega}^{-1} (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}_{\text{GLS}}).\end{aligned}$$

Adicionalmente

$$\begin{aligned}\mathbf{e}_* &= \mathbf{B}^{-1} \mathbf{Y} - \mathbf{B}^{-1} \mathbf{X} (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{Y} \\ &= \mathbf{B}^{-1} \mathbf{Y} - \mathbf{B}^{-1} \mathbf{X} (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{B}^{-\top} \mathbf{B}^{-1} \mathbf{Y}.\end{aligned}$$

De este modo,

$$\mathbf{e}_* = (\mathbf{I} - \mathbf{H}_\Omega) \mathbf{Y}_*,$$

con¹

$$\mathbf{H}_\Omega = \mathbf{B}^{-1} \mathbf{X} (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{B}^{-\top}.$$

¹Evidentemente $\mathbf{H}_\Omega^\top = \mathbf{H}_\Omega$ y $\mathbf{H}_\Omega^2 = \mathbf{H}_\Omega$.

Errores correlacionados

Desafortunadamente, en general la matriz Ω no es conocida y requiere ser estimada. Si $\widehat{\Omega}$ es un estimador de Ω , entonces

$$\widehat{\beta}_{\text{EGLS}} = (\mathbf{X}^\top \widehat{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \widehat{\Omega}^{-1} \mathbf{Y}.$$

Se debe notar que las propiedades de $\widehat{\beta}_{\text{EGLS}}$ son difíciles de caracterizar.

Suponga que

$$\Omega = (1 - \rho) \mathbf{I} + \rho \mathbf{1} \mathbf{1}^\top,$$

con ρ un parámetro desconocido y considere $\mathbf{X} = (\mathbf{1}, \mathbf{Z})$ tal que $\mathbf{Z}^\top \mathbf{1} = \mathbf{0}$. Fijando $\rho = \widehat{\rho}$ con $\widehat{\rho}$ algún estimador de ρ , podemos notar que

$$\widehat{\beta}_{\text{EGLS}} = (\mathbf{X}^\top \widehat{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \widehat{\Omega}^{-1} \mathbf{Y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y},$$

donde

$$\widehat{\beta} = (\widehat{\delta}, \widehat{\theta}^\top)^\top, \quad \widehat{\delta} = \overline{Y}, \quad \widehat{\theta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Errores correlacionados

Un caso particular importante, corresponde a **mínimos cuadrados ponderados** en cuyo caso $\text{Cov}(\epsilon) = \sigma^2 \mathbf{W}^{-1}$ donde $\mathbf{W} = \text{diag}(\omega_1, \dots, \omega_n)$ con $\omega_i > 0, \forall i$. De este modo,

$$\hat{\boldsymbol{\beta}}_{\text{WLS}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{Y}.$$

Note que este estimador es solución del problema

$$\min_{\boldsymbol{\beta}} Q_W(\boldsymbol{\beta}), \quad Q_W(\boldsymbol{\beta}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

Además,

$$Q_W(\boldsymbol{\beta}) = \sum_{i=1}^n \omega_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2.$$

Observación:

Consideraciones computacionales sobre GLS y WLS son dadas por ejemplo en el Capítulo 4 de Björk (1996)²

²Numerical Methods for Least Squares Problems, SIAM.

Funciones de varianza

El objetivo de esta sección es considerar modelos de regresión heterocedásticos, tal que

$$\mathbb{E}(Y_i) = \mu_i, \quad \text{var}(Y_i) = \sigma^2 g^2(\mathbf{z}_i; \mu_i, \phi), \quad i = 1, \dots, n,$$

donde $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$, \mathbf{x}_i y \mathbf{z}_i representan vectores de covariables (que podrían ser iguales), $\boldsymbol{\beta}$ son coeficientes de regresión, g es función de varianza (que permite modelar la heterogeneidad), $\sigma^2 > 0$ y ϕ son parámetros de escala desconocidos.

Ejemplo:

Considere

$$\text{var}(Y_i) = \sigma^2 \{g(\mathbf{x}_i; \boldsymbol{\beta})\}^{2\phi}, \quad \phi > 0.$$

Si suponemos $g(\mathbf{x}_i; \boldsymbol{\beta}) = \mathbf{x}_i^\top \boldsymbol{\beta}$ y $\phi = \frac{1}{2}$ tenemos la **estructura de varianza Poisson**, mientras que $\phi = 1$ es de **tipo-gama**.

Funciones de varianza

Ejemplo:

Ejemplos habituales de funciones de varianza son los siguientes:

(a) Función de varianza cuadrática

$$\sigma g(\mathbf{z}_i; \mu_i, \phi) = 1 + \phi_1 z_{1i} + \phi_2 z_{2i}^2.$$

(b) Modelo potencia extendido

$$\text{var}(Y_i) = \sigma^2 (\phi_1 + \phi_2 \mu_i^{\phi_3}).$$

(c) Modelo exponencial

$$\text{var}(Y_i) = \sigma^2 \exp(2\phi \mu_i).$$

(d) También puede depender de ϕ según un predictor lineal

$$\text{var}(Y_i) = \sigma^2 \exp(2\mathbf{z}_i^\top \phi).$$

Funciones de varianza

Considere el modelo

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \epsilon_i, \quad i = 1, \dots, n,$$

tal que

$$\mathbb{E}(Y_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \quad \text{var}(Y_i) = \sigma^2 / \omega_i,$$

para constantes conocidas $\omega_i > 0$, $i = 1, \dots, n$.

Bajo el supuesto $\epsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{W}^{-1})$, con $\mathbf{W} = \text{diag}(\omega_1, \dots, \omega_n)$. Es fácil notar que el estimador $\hat{\boldsymbol{\beta}}_{WLS}$ minimiza la función

$$Q_W(\boldsymbol{\beta}) = \sum_{i=1}^n \omega_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2.$$

Además, el estimador $\hat{\boldsymbol{\beta}}_{WLS}$ resuelve las siguientes ecuaciones de estimación

$$\mathbf{X}^\top \mathbf{W} (\mathbf{Y} - \mathbf{X} \boldsymbol{\beta}) = \mathbf{0},$$

o equivalentemente

$$\sum_{i=1}^n \omega_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta}) \mathbf{x}_i = \mathbf{0}.$$

Funciones de varianza

El estimador ML para σ^2 asume la forma:

$$\hat{\sigma}_{WLS}^2 = \frac{1}{n} \sum_{i=1}^n \omega_i (Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{WLS})^2.$$

Observación:

El problema anterior puede ser resuelto usando OLS en el siguiente ‘problema modificado’

$$\mathbf{W}^{1/2} \mathbf{Y}, \quad \mathbf{W}^{1/2} \mathbf{X}.$$

En la práctica es bastante improbable conocer las constantes ω_i , $i = 1, \dots, n$.

El método WLS sugiere un procedimiento natural para la estimación de varianzas heterogéneas.

Funciones de varianza

Suponga el modelo

$$\mathbb{E}(Y_i) = \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}, \quad \text{var}(Y_i) = \sigma^2 g^2(\mathbf{z}_i; \mu_i, \phi),$$

con ϕ conocido.

Una estrategia de estimación es usar un [algoritmo de mínimos cuadrados iterativamente ponderados \(IWLS\)](#).

Funciones de varianza

Algoritmo 1: IWLS para estimación de varianzas

1 **begin**

2 Considerar una estimación inicial para β , digamos $\beta^{(0)}$, resolviendo

$$\sum_{i=1}^n (Y_i - \mathbf{x}_i^\top \beta) \mathbf{x}_i = \mathbf{0}.$$

y hacemos $k = 0$.

3 Construir los “pesos”

$$\omega_i^{(k)} = 1/g^2(\mathbf{z}_i; \mu_i^{(k)}, \phi), \quad \mu_i^{(k)} = \mathbf{x}_i^\top \beta^{(k)}.$$

4 Actualizar $\beta^{(k+1)}$, resolviendo

$$\sum_{i=1}^n \omega_i^{(k)} (Y_i - \mathbf{x}_i^\top \beta) \mathbf{x}_i = \mathbf{0},$$

hacer $k = k + 1$ y volver a **Paso 3**.

5 **end**

Funciones de varianza

Evidentemente el **Paso 4** del Algoritmo 1, debe ser resuelta usando mínimos cuadrados ponderados.

En el algoritmo anterior σ^2 puede ser estimado por analogía a WLS. Específicamente, podemos considerar

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\omega}_i (Y_i - \mathbf{x}_i^\top \hat{\beta})^2,$$

donde $\hat{\omega}_i$ ($i = 1, \dots, n$) y $\hat{\beta}$ representan los valores de ω_i y β a la convergencia del Algoritmo 1.

Alternativamente, es posible incorporar una etapa adicional al Algoritmo 1 como:

$$5' \quad \sigma^{2(k+1)} = \frac{1}{n} \sum_{i=1}^n \omega_i^{(k)} (Y_i - \mathbf{x}_i^\top \beta^{(k+1)})^2.$$

Funciones de varianza

Claramente, no siempre es posible especificar valores para ϕ . Para simplificar la exposición considere

$$Y_i \stackrel{\text{ind}}{\sim} N(\mu_i, \sigma^2 g^2(z_i; \mu_i, \phi)), \quad i = 1, \dots, n,$$

con $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$.

Defina la matriz diagonal

$$\mathbf{G} = \mathbf{G}(\boldsymbol{\beta}, \phi) = \text{diag}(g^2(z_1; \mu_1, \phi), \dots, g^2(z_n; \mu_n, \phi)).$$

De este modo, el modelo anterior puede ser escrito como

$$\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{G}),$$

con función de densidad conjunta

$$f(\mathbf{y}) = |2\pi\sigma^2 \mathbf{G}|^{-1/2} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{G}^{-1} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \right\}.$$

Funciones de varianza

La parte relevante de la función de log-verosimilitud es

$$\ell_n(\psi) = -\frac{1}{2} \log |\sigma^2 \mathbf{G}| - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{G}^{-1} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}),$$

con $\psi = (\boldsymbol{\beta}^\top, \sigma^2, \boldsymbol{\phi}^\top)^\top$. Por la estructura diagonal de \mathbf{G} tenemos que

$$\mathbf{G}^{-1} = \text{diag}(g^{-2}(\mathbf{z}_1; \mu_1, \boldsymbol{\phi}), \dots, g^{-2}(\mathbf{z}_n; \mu_n, \boldsymbol{\phi})),$$

$$\log |\sigma^2 \mathbf{G}| = \sum_{i=1}^n \log \sigma^2 g^2(\mathbf{z}_i; \mu_i, \boldsymbol{\phi}).$$

Esto permite escribir la log-verosimilitud como:

$$\begin{aligned} \ell_n(\psi) &= -\frac{1}{2} \sum_{i=1}^n \log \sigma^2 g^2(\mathbf{z}_i; \mu_i, \boldsymbol{\phi}) - \frac{1}{2\sigma^2} \sum_{i=1}^n \frac{(Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2}{g^2(\mathbf{z}_i; \mu_i, \boldsymbol{\phi})} \\ &= -\frac{1}{2} \sum_{i=1}^n \left\{ \frac{(Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2}{\sigma^2 g^2(\mathbf{z}_i; \mu_i, \boldsymbol{\phi})} + \log \sigma^2 g^2(\mathbf{z}_i; \mu_i, \boldsymbol{\phi}) \right\} \end{aligned}$$

Funciones de varianza

La estimación de parámetros se puede desarrollar como:

1. Para una estimación preliminar $\beta^{(k)}$ de β minimizar con relación a ϕ y σ^2 , la función perfilada:

$$\ell_*(\beta^{(k)}, \sigma^2, \beta) = -\frac{1}{2} \sum_{i=1}^n \left\{ \frac{(Y_i - \mathbf{x}_i^\top \beta^{(k)})^2}{\sigma^2 g^2(\mathbf{z}_i; \mu_i^{(k)}, \phi)} + \log \sigma^2 g^2(\mathbf{z}_i; \mu_i^{(k)}, \phi) \right\},$$

con $\mu_i^{(k)} = \mathbf{x}_i^\top \beta^{(k)}$. Diferenciando con relación a ϕ y σ^2 lleva a las ecuaciones de estimación:

$$\sum_{i=1}^n \frac{1}{g^4(\mathbf{z}_i; \mu_i^{(k)}, \phi)} \{r_i^2 - \sigma^2 g^2(\mathbf{z}_i; \mu_i^{(k)}, \phi)\} \mathbf{q}(\mu_i^{(k)}, \sigma, \phi) = \mathbf{0},$$

donde

$$\mathbf{q}(\mu_i^{(k)}, \sigma, \phi) = g^2(\mu_i^{(k)}, \phi) \begin{pmatrix} 1/\sigma \\ \mathbf{u}(\mu_i^{(k)}, \phi) \end{pmatrix},$$

y $\mathbf{u}(\mu_i^{(k)}, \phi)$ representa el vector de derivadas de $\log g(\mathbf{z}_i, \mu_i, \phi)$ con relación a ϕ , mientras que $r_i = Y_i - \mathbf{x}_i^\top \beta^{(k)}$.

Funciones de varianza

Inspección de la ecuación anterior permite notar que la estimación de σ y ϕ corresponde a WLS con “respuesta” r_i^2 , “función de regresión” $\sigma^2 g^2(z_i; \mu_i^{(k)}, \phi)$, “parámetros de regresión” $(\sigma, \phi^\top)^\top$, “pesos” $g^{-4}(z_i, \mu_i^{(k)}, \phi)$ y gradiente (matriz de diseño cuyas filas están dadas por) $\mathbf{q}(\mu_i^{(k)}, \sigma, \phi)$.

Finalmente este paso debe ser alternado con

2. Actualizar $\beta^{(k+1)}$ como la solución del problema mínimos cuadrados ponderados

$$\mathbf{X}^\top \mathbf{G}^{-1} (\mathbf{Y} - \mathbf{X}\beta) = \mathbf{0},$$

donde $\mathbf{G} = \mathbf{G}(\beta^{(k)}, \phi^{(k+1)})$.