

# **IECD-325: Análisis de residuos y leverages**

**Felipe Osorio**

[felipe.osorio@uv.cl](mailto:felipe.osorio@uv.cl)

## Análisis de residuos

Suponga el modelo lineal,

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon},$$

con los Supuestos A1-A4. El vector de residuos es dado por:

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{H})\mathbf{Y},$$

con  $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top$ , es decir  $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y} = \hat{\mathbb{E}}(\mathbf{Y})$ .

Bajo el supuesto de normalidad  $\mathbf{Y} \sim \mathcal{N}_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$ , tenemos

$$\mathbf{e} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2(\mathbf{I} - \mathbf{H})),$$

es decir

$$\mathbb{E}(e_i) = 0, \quad \text{var}(e_i) = \sigma^2(1 - h_{ii}), \quad \text{Cov}(e_i, e_j) = -\sigma^2 h_{ij}.$$

De ahí que los residuos tienen varianzas diferentes y son correlacionados.

## Residuos en regresión lineal

Suponga que  $\sigma^2$  es conocido, de este modo

$$z_i = \frac{e_i}{\sigma} \sim N(0, 1).$$

Mientras que, el **residuo estandarizado** es definido como:

$$r_i = \frac{e_i}{s\sqrt{1 - h_{ii}}}, \quad i = 1, \dots, n.$$

Cook y Weisberg (1982)<sup>1</sup> mostraron que

$$\frac{r_i^2}{n-p} \sim \text{Beta}\left(\frac{1}{2}, \frac{n-p-1}{2}\right),$$

de este modo

$$E(r_i) = 0, \quad \text{var}(r_i) = 1, \quad \text{Cov}(r_i, r_j) = \frac{-h_{ij}}{\sqrt{(1-h_{ii})(1-h_{jj})}}.$$

---

<sup>1</sup>Residual and Influence in Regression, Chapman & Hall

## Residuos en regresión lineal

Considere el **residuo studentizado**:

$$t_i = \frac{e_i}{s_{(i)}\sqrt{1-h_{ii}}}, \quad i = 1, \dots, n.$$

donde

$$s_{(i)}^2 = \frac{1}{n-p-1} \sum_{j \neq i}^n (y_j - \mathbf{x}_j^\top \hat{\boldsymbol{\beta}}_{(i)})^2,$$

$$\hat{\boldsymbol{\beta}}_{(i)} = (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{Y}_{(i)},$$

denotan los estimadores de  $\sigma^2$  y  $\boldsymbol{\beta}$  una vez que la  $i$ -ésima observación ha sido eliminada. Es decir,

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{(i)} \\ \mathbf{x}_i^\top \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} \mathbf{Y}_{(i)} \\ Y_i \end{pmatrix}$$

## Residuos en regresión lineal

Una interpretación interesante de  $t_i$  es que corresponde al estadístico  $t$  para probar la hipótesis  $H_0 : \gamma = 0$  en el [modelo de salto en la media](#), dado por:

$$Y_j = \mathbf{x}_j^\top \boldsymbol{\beta} + d_j \gamma + \epsilon_j, \quad j = 1, \dots, n,$$

donde  $d_j = 1$  si  $j = i$  y 0 en caso contrario.

El modelo puede ser escrito como:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{d}\gamma + \boldsymbol{\epsilon},$$

con  $\mathbf{d}_i = (0, 1, 0)^\top$  con un cero en la  $i$ -ésima posición.

Lo anterior permite notar que  $t_i \sim t(n - p - 1)$ , y de este modo,

$$\mathbb{E}(t_i) = 0, \quad \text{var}(t_i) = \frac{n - p - 1}{n - p - 3} \approx 1$$

# QQ-plot en regresión lineal

## Objetivo:

Evaluar desvios de normalidad de los residuos studentizados  $t_i$ 's.<sup>2</sup>

## Notación:

Considere  $Z_i = t_i$ , para  $i = 1, \dots, n$

## Idea:

Comparar la CDF muestral para los  $Z_i$ 's contra la CDF de la  $N(0, 1)$ .

---

<sup>2</sup>La descripción es válida para otras medidas de interés.

## QQ-plot en regresión lineal

Asuma que los **residuos**  $Z_i$  están ordenados

$$Z_{(1)} \leq Z_{(2)} \leq \cdots \leq Z_{(n)},$$

los  $Z_{(i)}$  son los cuantiles de la CDF muestral, definida como

$$\text{Proportion}(Z \leq Z_{(i)}) = \frac{i}{n}.$$

Los cuantiles de la distribución teórica, son dados por:

$$q_i^* = \Phi^{-1}\left(\frac{i}{n}\right).$$

Si los errores son **aproximadamente normales**, se debe tener que el gráfico de los pares  $(q_1^*, Z_{(1)}), \dots, (q_n^*, Z_{(n)})$  sea la recta identidad.

## QQ-plot en regresión lineal

Se ha sugerido la siguiente aproximación para la esperanza de los estadísticos de orden desde  $N(0, 1)$  como:

$$q_i = \Phi^{-1} \left( \frac{i - 3/8}{n + 1/4} \right),$$

de este modo, se utilizará el gráfico cuantil-cuantil (QQ-plot) de los pares  $(q_i, Z_{(i)})$ .

### *Observación:*

- ▶ Podemos construir QQ-plots para diversas distribuciones.<sup>3</sup>
- ▶ Es difícil chequear visualmente desvios de la distribución de interés.

---

<sup>3</sup>Por ejemplo,  $\chi^2$ ,  $t$  de Student, Poisson, Gama, etc.

## QQ-plot con envelopes en regresión lineal

Envelopes simulados son herramientas gráficas para chequear el ajuste de un modelo. Atkinson (1985)<sup>4</sup> sugirió usar el siguiente procedimiento:

- ▶ Ajustar un modelo de regresión lineal, calcular residuos y estandarizar para obtener varianza unitaria.
- ▶ Generar  $M$  ( $\approx 1000$ ) muestras como respuesta. Para cada muestra ajuste el mismo modelo y calcule los residuos estandarizados
- ▶ Ordenar todos los conjuntos de residuos estandarizados.
- ▶ El envelope consiste de los cuantiles 2.5% inferior y superior de los residuos estandarizados generados en cada posición.

---

<sup>4</sup>Plots, Transformations and Regressions, Oxford University Press.

## QQ-plot con envelopes en regresión lineal<sup>5</sup>

```
1 envelop.norm <- function(object, nsamples = 1000, alpha = 0.05) {  
2   x <- model.matrix(object)  
3   n <- nrow(x); p <- ncol(x)  
4   H <- x %*% solve(crossprod(x), t(x))  
5   ti <- rstudent(object)  
6   Id <- diag(n)  
7   epsilon <- matrix(0, n, nsamples)  
8   e <- matrix(0, n, nsamples)  
9   e1 <- e2 <- numeric(n)  
10  for (i in 1:nsamples) {  
11    epsilon[,i] <- rnorm(n)  
12    e[,i] <- (Id - H) %*% epsilon[,i]  
13    u <- diag(Id - H)  
14    e[,i] <- e[,i] / sqrt(u)  
15    e[,i] <- sort(e[,i])  
16  }  
17  for (i in 1:n) {  
18    eo <- quantile(e[i,], c(alpha / 2, 1 - alpha / 2))  
19    e1[i] <- eo[1]; e2[i] <- eo[2]  
20  }  
21  res <- structure(list(res = sort(ti), elim = cbind(e1,e2)),  
22                      label = deparse(object$call$formula))  
23  class(res) <- "envelope"  
24  res  
25}  
26}
```

<sup>5</sup>Versión preliminar, no recomendable para  $n$  “grande”.

## QQ-plot con envelopes en regresión lineal

```
1 envelope <- function(object, nsamples = 1000, alpha = 0.05) {
2     n <- length(r <- resid(object))
3     p <- length(coef(object))
4     Y <- scale(qr.resid(qr(model.matrix(object)),
5         matrix(rnorm(n * nsamples), n, nsamples)),
6         F, T) * sqrt((n - 1) / (n - p))
7     Y[,] <- Y[order(col(Y),Y)]
8     Y <- matrix(Y[order(row(Y),Y)], nsamples, n)
9     x0 <- quantile(1:nsamples, c(alpha / 2, 1 - alpha / 2))
10    if (all(x0 %% 1 == 0)) elim <- t(Y[x0,])
11    else {
12        x1 <- c(floor(x0), ceiling(x0))
13        elim <- cbind(Y[x1[1],] + (Y[x1[3],] - Y[x1[1],]) /
14            (x1[3] - x1[1]) * (x0[1] - x1[1]),
15            Y[x1[2],] + (Y[x1[4],] - Y[x1[2],]) /
16            (x1[4] - x1[2]) * (x0[2] - x1[2]))
17    }
18    res <- sort(r)
19    res <- res / sqrt(sum(res^2) / (n - p))
20    res <- structure(list(res = res, elim = elim),
21                      label = deparse(object$call$formula))
22    class(res) <- "envelope"
23    res
24 }
25 }
```

## QQ-plot con envelopes en regresión lineal

```
1 plot.envelope <- function(x, ...) {
2   n <- length(x$res)
3   ylim <- range(x$res[c(1,n)], x$elim[c(1,n),])
4   nscores <- qnorm(ppoints(n))
5   oldpar <- par(pty = "s"); on.exit(par(oldpar))
6   plot(nscores, x$res, pch = 1, ylim = ylim,
7     xlab = "Normal scores", ylab = "Sorted residuals",
8     main = attr(x, "label"))
9   lines(nscores, x$elim[,1]); lines(nscores, x$elim[,2])
10  invisible(x)
11 }
12
13 print.envelope <- function(x, ...) {
14   lo <- x$res < x$elim[,1]
15   hi <- x$res > x$elim[,2]
16   flash <- rep("", length(lo))
17   flash[lo] <- "<"; flash[hi] <- ">"
18   if (any(lo | hi))
19     print(cbind(do.call("data.frame", x), flash = flash)[lo | hi
20       ,])
21   else cat("All points within envelope\n")
22   invisible(x)
23 }
```

## Herencia de la estatura (Weisberg, 2005)

*Ejemplo (Herencia de la estatura):*

Se recolectó la altura de  $n = 1375$  madres en UK (bajo 65 años) y una de sus hijas adultas (sobre 18 años).


Cargamos el conjunto de datos y hacemos un gráfico:

```
1 > load("Heights.rda") # carga datos
2 > plot(dheight ~ mheight, data = Heights)
3
```


Ajuste de un modelo de regresión lineal simple

```
1 > fm <- lm(dheight ~ mheight, data = Heights)
2 > fm
3
4 Call:
5 lm(formula = dheight ~ mheight, data = Heights)
6
7 Coefficients:
8 (Intercept)      mheight
9        29.9174       0.5417
10
```

# Herencia de la estatura



(a) datos estatura




(b) recta ajustada


## Herencia de la estatura (Weisberg, 2005)

```
1 # interpreta script y ejecuta función 'envelope'
2 > source("envelope.lm.R")
3 > z <- envelope(fm)
4
5 # Salida
6 > z
7             res      elim.1      elim.2 flash
8 3     -2.9772192 -2.9389051 -2.4155563      <
9 194    -2.8837417 -2.8506620 -2.3725540      <
10 83     -2.8469003 -2.7768534 -2.3403934      <
11 81     -1.9256830 -2.1707912 -1.9326915      >
12 187    -1.9165152 -2.1591549 -1.9192914      >
13
14 ...
15
16 72     -1.7160276 -1.9010945 -1.7197547      >
17 997    0.7475798  0.7478225  0.8319662      <
18 1000   0.7493793  0.7494135  0.8349166      <
19
20 # calcula QQ-plots: paneles (a) y (b)
21 > plot(fm, which = 2)
22 > plot(z)
23
```

# Herencia de la estatura




(a) QQ-plot



(b) envelope

## Datos de Concha y Toro (Osorio y Galea, 2006)<sup>6</sup>

Rentabilidades mensuales de Concha y Toro vs. IPSA, ajustados por bonos de interés del Banco Central entre marzo/1990 a abril/1999.



<sup>6</sup> Statistical Papers 47, 31-38


# Datos de Concha y Toro

```
1 # carga datos 'CyT'  
2 > load("cyt.rda")  
3 > fm <- lm(formula = CyT ~ IPSA, data = cyt)  
4 > fm  
5  
6 Call:  
7 lm(formula = CyT ~ IPSA, data = cyt)  
8  
9 Coefficients:  
10 (Intercept)           IPSA  
11      0.01294       0.88840  
12  
13 # gráfico de CyT con ajuste  
14 > plot(formula = CyT ~ IPSA, data = cyt)  
15 > abline(coef(fm), lwd = 2, lty = 2, col = "red")  
16  
17 # calculo de QQ-plots  
18 > plot(fm, which = 2)  
19 > z <- envelope(fm)  
20 > plot(z)  
21
```


## Datos de Concha y Toro

```
1 # 71 observaciones (de 110) fuera de los límites!
2 > z
3
4      res      elim.1      elim.2 flash
5 21 -1.734317225 -3.436526273 -1.9634593   >
6 27 -1.415056927 -2.788774059 -1.7887230   >
7 100 -1.404756702 -2.419605631 -1.6748655   >
8 50 -1.324027912 -2.210958830 -1.5721054   >
9 54 -1.169203402 -2.054624463 -1.4703409   >
10 51 -1.153477009 -1.934805526 -1.3798186   >
11 11 -1.096119396 -1.838246685 -1.3320742   >
12 47 -1.070881256 -1.742209010 -1.2793535   >
13 26 -1.007932910 -1.660524800 -1.2222670   >
14 46 -0.957413175 -1.585646847 -1.1571871   >
15 22 -0.939792570 -1.516926733 -1.1140743   >
16 40 -0.936821200 -1.471364845 -1.0692352   >
17 42 -0.904023872 -1.396710446 -1.0331150   >
18 64 -0.875677184 -1.345638331 -0.9933418   >
19 24 -0.866049026 -1.284654537 -0.9480642   >
20
21 ...
22
23 9 -0.828768419 -1.236817210 -0.9129081   >
24 25 3.757662579  1.787389608  2.7912823   >
25 12 6.047936818  1.950943630  3.4974732   >
```

# Datos de Concha y Toro




(a) datos Concha y Toro




(b) recta ajustada

# Datos de Concha y Toro



(a) QQ-plot



(b) envelope

## Leverages en regresión lineal

Tenemos que

$$\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}, \quad \mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top. \quad (1)$$

Es fácil notar que,

$$\hat{Y}_i = \sum_{j=1}^n h_{ij} Y_j = h_{ii} Y_i + \sum_{j \neq i} h_{ij} Y_j, \quad (2)$$

es decir el **valor predicho** es una combinación lineal de las respuestas observadas con pesos dados por los elementos de la matriz de proyección  $\mathbf{H}$ .

La matriz  $\mathbf{H}$  tiene las siguientes propiedades:

### Propiedad 1:

$\mathbf{H}$  es simétrica e idempotente con  $\text{rg}(\mathbf{H}) = \text{tr}(\mathbf{H}) = p$ .

## Leverages en regresión lineal

### Propiedad 2:

Los elementos diagonales de  $\mathbf{H}$  están acotados como:

$$0 \leq h_{ii} \leq 1, \quad i = 1, \dots, n.$$

En efecto, desde

$$\hat{\mathbf{Y}} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{H}), \quad \mathbf{e} \sim \mathcal{N}(\mathbf{0}, \sigma^2 (\mathbf{I} - \mathbf{H})).$$

De este modo,

$$\text{var}(\hat{Y}_i) = \sigma^2 h_{ii}, \quad \text{var}(e_i) = \sigma^2 (1 - h_{ii}),$$

de ahí que obtenemos el resultado.

Para otra demostración, ver [Resultado A.6](#) desde el Apéndice A de las notas de clase.

## Leverages en regresión lineal

### Propiedad 3:

Tenemos,

$$h_{ii} = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i, \quad i = 1, \dots, n.$$

Además,

$$\bar{h} = \frac{1}{n} \sum_{i=1}^n h_{ii} = \frac{1}{n} \text{tr}(\mathbf{H}) = \frac{p}{n}.$$

### Propiedad 4:

Sea  $\widetilde{\mathbf{X}}$  la matriz de datos centrados. En este caso, los elementos diagonales de  $\widetilde{\mathbf{H}}$  están dados por

$$\tilde{h}_{ii} = (\mathbf{x}_i - \bar{\mathbf{x}})^\top (\widetilde{\mathbf{X}}^\top \widetilde{\mathbf{X}})^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}), \quad i = 1, \dots, n.$$

Luego  $\tilde{h}_{ii}$  es la distancia ponderada desde  $\mathbf{x}_i$  al centroide  $\bar{\mathbf{x}}$ .

## Leverages en regresión lineal

### *Observación:*

Hoaglin y Welsch (1978)<sup>7</sup> sugieren que aquellas observaciones que exceden dos veces su promedio

$$h_{ii} > 2p/n \quad (= 2\bar{h})$$

indican un alto leverage. Mientras que Huber (1981)<sup>8</sup> sugirió identificar observaciones tal que

$$h_{ii} > 0.5,$$

independiente de  $n$  o  $p$ .

### *Regla de trabajo:*

En la práctica se debe prestar atención a casos inusualmente grandes **con relación al resto** de  $h_{ii}$ 's.

---

<sup>7</sup>The American Statistician 32, 17-22.

<sup>8</sup>Robust Statistics. Wiley, New York.

## Leverages en regresión lineal

### Propiedad 5:

Desde Ecuación (1), sigue que

$$\frac{\partial \hat{Y}}{\partial Y^\top} = H,$$

y en particular  $\partial \hat{Y}_i / \partial Y_i = h_{ii}$ , para  $i = 1, \dots, n$ .

### Propiedad 6:

Si el modelo tiene intercepto, entonces  $H\mathbf{1} = \mathbf{1}$ .


Considere  $X = (\mathbf{1}, X_1)$ . Sabemos que  $HX = X$ , y de ahí que

$$H(\mathbf{1}, X_1) = (\mathbf{1}, X_1),$$

y el resultado sigue.





# Cuarteto de regresiones “idénticas” de Anscombe (1973)

Anscombe's 4 Regression data sets



# Leverages: Datos de Anscombe

Leverage plots. Anscombe's data sets



## Leverages: Datos de Concha y Toro

```
1 # ajuste de datos 'CyT', almacenando 'x'
2 > fm <- lm(CyT ~ IPSA, data = cyt, x = TRUE)
3 > x <- fm$x # extrae 'x'
4 > z <- influence(fm)
5 > attributes(z)
6 $names
7 [1] "hat"      "coefficients"    "sigma"      "wt.res"
8
9 # extrae 'leverages' y calcula punto de corte
10 > hats <- z$hat
11 > n <- nrow(x)
12 > p <- ncol(x)
13 > cutoff <- 2 * p / n
14
15 > which <- hats > cutoff
16 > idx <- 1:n
17 > obs <- idx[which]
18
19 # gráfico de leverages con punto de corte
20 > plot(z$hat, ylim = c(0,0.18), ylab = "Leverages")
21 > abline(h = cutoff, lwd = 2, lty = 2, col = "red")
22 > text(obs, hat[obs], labels = as.character(obs), pos = 3)
23
24 # otros métodos para calcular leverages
25 > hats <- hatvalues(fm)
26 > hats <- hat(x, intercept = FALSE)
27
```

## Leverages: Datos de Concha y Toro

