

IECD-325: Métodos de selección automática

Felipe Osorio

felipe.osorio@uv.cl

Suponga el modelo de regresión¹

$$Y_i = \beta_1 x_{i1} + \cdots + \beta_K x_{iK} + \epsilon_i, \quad i = 1, \dots, n,$$

que puede ser escrito como $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ con los supuestos habituales, y $\mathbf{X} \in \mathbb{R}^{n \times K}$, $\boldsymbol{\beta} = (\beta_1, \dots, \beta_K)^\top$.

Suponga que particionamos

$$\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2),$$

donde $\mathbf{X}_1 \in \mathbb{R}^{n \times p}$ y $\mathbf{X}_2 \in \mathbb{R}^{n \times (K-p)}$ y análogamente $\boldsymbol{\beta} = (\boldsymbol{\beta}_1^\top, \boldsymbol{\beta}_2^\top)^\top$. El modelo adopta la forma,

$$\mathbf{Y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\epsilon}.$$

Objetivo:

Deseamos identificar las variables “significativas” con coeficientes no nulos.

¹Si $x_{i1} = 1$, para $i = 1, \dots, n$, tenemos un intercepto en el modelo.

Suponga que sospechamos que los coeficientes asociados a las $(K-p)$ -variables en \mathbf{X}_2 son cero. Es decir, deseamos probar $H_0 : \beta_2 = \mathbf{0}$.

En otras palabras, debemos discriminar entre 2 modelos, uno con K variables y el otro con p variables. Para esto, podemos considerar el estadístico F , dado por:

$$F = \left(\frac{n - K}{K - p} \right) \frac{\text{RSS}_p - \text{RSS}_K}{\text{RSS}_K}.$$

Por otro lado, suponga que $K = p + 1$, así

$$F = (n - p - 1) \frac{\text{RSS}_p - \text{RSS}_{p+1}}{\text{RSS}_{p+1}}. \quad (1)$$

Consideraremos los siguientes procedimientos:

- ▶ Selección forward.
- ▶ Eliminación backward.
- ▶ Método stepwise.

Adicionalmente, un procedimiento que ha ganado popularidad es **regresión lasso**, el cual resuelve el problema

$$\min_{\beta} Q_1(\beta), \quad Q_1(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j|,$$

que corresponde a un método de selección de regresores.

Selección forward (SF):

Este método añade variables regresoras una en cada vez, partiendo desde el modelo más simple, y una vez que una variable ingresa al modelo, esta **no** es retirada.

La elección de cual variable ingresa al inicio es arbitraria. Sin embargo, es usual inicializar el procedimiento con el modelo que solo tiene intercepto.

Calculamos (1) con $p = 1$ para todas las $m = K - 1$ variables regresoras restantes, y escogemos aquella tal que (1) sea la mayor.

Luego de eso, repetimos el procedimiento para $p = 2, 3, \dots$ seleccionando en cada etapa una variable que no se había seleccionado previamente.

Es decir, añadimos la variable x_j al modelo con p -regresores, si:

$$F_j = \frac{\text{RSS}_p - \text{RSS}_{p+1}}{\text{RSS}_{p+1} / (n - p - 1)} > F_{\text{IN}},$$

donde $F_{\text{IN}} = F_{1-\alpha}(1, n - p - 1)$ para algún valor de α ,² o alternativamente $F_{\text{IN}} = 2$.

²Se recomienda usar $0.15 \leq \alpha \leq 0.25$.

Eliminación backward (EB):

Este método se inicia con aquél que tiene K variables (i.e., el modelo más complejo) y elimina una variable en cada ocasión.

Es decir, se debe calcular (1) y debemos retirar la variable que ocasiona la menor contribución.

Es decir, eliminamos la variable x_j del modelo con p -regresores, si:

$$F_j = \frac{RSS_{p-1} - RSS_p}{RSS_p / (n - p)} < F_{OUT},$$

donde $F_{OUT} = F_{1-\alpha}(1, n - p)$ para algún valor de α , o alternativamente $F_{OUT} = 2$.

Método stepwise:

Este método combina selección forward y eliminación backward el cual corresponde a desarrollar un paso SF seguido por un paso EB en cada etapa.

Este algoritmo inicia con el modelo más simple y añade variables si el estadístico F asociado³ es mayor que F_{IN} o elimina variables si es menor que F_{OUT} , siempre que $F_{OUT} \leq F_{IN}$.

³ver Ecuación (1).

Observaciones:

- ▶ El conjunto de regresores obtenidos mediante cada uno de los métodos puede ser diferente.
- ▶ Estos métodos pueden fallar en detectar el mejor subconjunto de regresores.
- ▶ El método EB asume que \mathbf{X} tiene rango completo, en caso contrario (o si el número de potenciales regresores es muy alto), las únicas opciones factibles son SF o stepwise.
- ▶ Criterios de selección de modelos, como C_p , s_p^2 y AIC_p pueden ser usados como mecanismos de búsqueda.⁴

⁴En R están disponibles las funciones `step` o `stepAIC`.

usando stepAIC

```
1 # ajustando el modelo de regresión
2 fm <- lm(y ~ ., data = portland)
3
4 # cargando la biblioteca MASS
5 library(MASS)
6
7 # ejecutando eliminación backward
8 > EB <- stepAIC(fm, trace = TRUE, direction = "backward")
9 Start:  AIC=26.94
10 y ~ x1 + x2 + x3 + x4
11
12      Df Sum of Sq    RSS    AIC
13 - x3    1    0.1091 47.973 24.974
14 - x4    1    0.2470 48.111 25.011
15 - x2    1    2.9725 50.836 25.728
16 <none>                47.864 26.944
17 - x1    1   25.9509 73.815 30.576
18
19 Step:  AIC=24.97
20 y ~ x1 + x2 + x4
21
22      Df Sum of Sq    RSS    AIC
23 <none>                47.97 24.974
24 - x4    1     9.93   57.90 25.420
25 - x2    1    26.79   74.76 28.742
26 - x1    1   820.91 868.88 60.629
```

```
1 # resumen del proceso
2 > EB$anova
3 Stepwise Model Path
4 Analysis of Deviance Table
5
6 Initial Model:
7 y ~ x1 + x2 + x3 + x4
8
9 Final Model:
10 y ~ x1 + x2 + x4
11
12
13      Step Df Deviance Resid. Df Resid. Dev      AIC
14 1
15 2 - x3   1   0.10909         9   47.97273  24.97388
```

usando stepAIC

```
1 # modelo inicial y 'full'
2 > empty <- lm(y ~ 1, data = portland)
3 > full <- formula(y ~ x1 + x2 + x3 + x4)
4
5 # ejecutando selección forward
6 > SF <- stepAIC(empty, direction = "forward", scope = full)
7 Start:  AIC=71.44
8 y ~ 1
9
10      Df Sum of Sq    RSS    AIC
11 + x4   1   1831.90  883.87 58.852
12 + x2   1   1809.43  906.34 59.178
13 + x1   1   1450.08 1265.69 63.519
14 + x3   1    776.36 1939.40 69.067
15 <none>      2715.76 71.444
16
17 ...
```

usando stepAIC

```
1 # ... continuación
2
3 Step:  AIC=58.85
4 y ~ x4
5
6           Df Sum of Sq      RSS      AIC
7 + x1       1      809.10   74.76  28.742
8 + x3       1      708.13  175.74  39.853
9 <none>                      883.87  58.852
10 + x2       1       14.99  868.88  60.629
11
12 Step:  AIC=28.74
13 y ~ x4 + x1
14
15           Df Sum of Sq      RSS      AIC
16 + x2       1      26.789  47.973  24.974
17 + x3       1      23.926  50.836  25.728
18 <none>                      74.762  28.742
19
20 Step:  AIC=24.97
21 y ~ x4 + x1 + x2
22
23           Df Sum of Sq      RSS      AIC
24 <none>                      47.973  24.974
25 + x3       1      0.10909  47.864  26.944
```

```
1 # resumen del proceso
2 > SF$anova
3 Stepwise Model Path
4 Analysis of Deviance Table
5
6 Initial Model:
7 y ~ 1
8
9 Final Model:
10 y ~ x4 + x1 + x2
11
12
13      Step Df    Deviance Resid. Df Resid. Dev      AIC
14 1
15 2 + x4   1 1831.89616      11    883.86692  58.85164
16 3 + x1   1  809.10480      10    74.76211  28.74170
17 4 + x2   1   26.78938       9     47.97273  24.97388
```

usando stepAIC

```
1 # ejecutando el método stepwise
2 > SW <- stepAIC(empty, direction = "both", scope = full)
3 Start:  AIC=71.44
4 y ~ 1
5
6      Df Sum of Sq      RSS      AIC
7 + x4    1   1831.90   883.87  58.852
8 + x2    1   1809.43   906.34  59.178
9 + x1    1   1450.08  1265.69  63.519
10 + x3    1    776.36  1939.40  69.067
11 <none>          2715.76  71.444
12
13 Step:  AIC=58.85
14 y ~ x4
15
16      Df Sum of Sq      RSS      AIC
17 + x1    1    809.10    74.76  28.742
18 + x3    1    708.13   175.74  39.853
19 <none>          883.87  58.852
20 + x2    1     14.99   868.88  60.629
21 - x4    1   1831.90  2715.76  71.444
22
23 ...
```

usando stepAIC

```
1 # ... continuación
2
3 Step:  AIC=28.74
4 y ~ x4 + x1
5
6           Df Sum of Sq      RSS      AIC
7 + x2       1      26.79    47.97 24.974
8 + x3       1      23.93    50.84 25.728
9 <none>                74.76 28.742
10 - x1       1     809.10   883.87 58.852
11 - x4       1    1190.92 1265.69 63.519
12
13 Step:  AIC=24.97
14 y ~ x4 + x1 + x2
15
16           Df Sum of Sq      RSS      AIC
17 <none>                47.97 24.974
18 - x4       1       9.93    57.90 25.420
19 + x3       1       0.11    47.86 26.944
20 - x2       1     26.79    74.76 28.742
21 - x1       1    820.91   868.88 60.629
```

```
1 # resumen del proceso
2 > SW$anova
3 Stepwise Model Path
4 Analysis of Deviance Table
5
6 Initial Model:
7 y ~ 1
8
9 Final Model:
10 y ~ x4 + x1 + x2
11
12
13      Step Df    Deviance Resid. Df Resid. Dev      AIC
14 1
15 2 + x4   1 1831.89616      11    883.86692 58.85164
16 3 + x1   1  809.10480      10    74.76211 28.74170
17 4 + x2   1   26.78938       9     47.97273 24.97388
```