

MAT-266: Análisis de residuos y leverages

Felipe Osorio

`fosorios.mat.utfsm.cl`

Departamento de Matemática, UTFSM



Suponga el modelo lineal,

$$Y = X\beta + \epsilon,$$

con los Supuestos A1-A4. El vector de residuos es dado por:

$$e = Y - \hat{Y} = (I - H)Y,$$

con $H = X(X^\top X)^{-1}X^\top$, es decir $\hat{Y} = HY = \hat{E}(Y)$.

Bajo el supuesto de normalidad $Y \sim N_n(X\beta, \sigma^2 I)$, tenemos

$$e \sim N_n(0, \sigma^2(I - H)),$$

es decir

$$E(e_i) = 0, \quad \text{var}(e_i) = \sigma^2(1 - h_{ii}), \quad \text{Cov}(e_i, e_j) = -\sigma^2 h_{ij}.$$

De ahí que los residuos tienen **varianzas diferentes** y **son correlacionados**.



Suponga que σ^2 es conocido, de este modo

$$z_i = \frac{e_i}{\sigma} \sim N(0, 1).$$

Mientras que, el **residuo estandarizado** es definido como:

$$r_i = \frac{e_i}{s\sqrt{1 - h_{ii}}}, \quad i = 1, \dots, n.$$

Cook y Weisberg (1982)¹ mostraron que

$$\frac{r_i^2}{n - p} \sim \text{Beta}\left(\frac{1}{2}, \frac{n - p - 1}{2}\right),$$

de este modo

$$E(r_i) = 0, \quad \text{var}(r_i) = 1, \quad \text{Cov}(r_i, r_j) = \frac{-h_{ij}}{\sqrt{(1 - h_{ii})(1 - h_{jj})}}.$$

¹Residual and Influence in Regression, Chapman & Hall

Considere el **residuo studentizado**:

$$t_i = \frac{e_i}{s_{(i)} \sqrt{1 - h_{ii}}}, \quad i = 1, \dots, n.$$

donde

$$s_{(i)}^2 = \frac{1}{n - p - 1} \sum_{j \neq i}^n (y_j - \mathbf{x}_j^\top \hat{\boldsymbol{\beta}}_{(i)})^2,$$
$$\hat{\boldsymbol{\beta}}_{(i)} = (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{Y}_{(i)},$$

denotan los estimadores de σ^2 y $\boldsymbol{\beta}$ una vez que la i -ésima observación ha sido eliminada. Es decir,

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{(i)} \\ \mathbf{x}_i^\top \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} \mathbf{Y}_{(i)} \\ Y_i \end{pmatrix}$$



Una interpretación interesante de t_i es que corresponde al estadístico t para probar la hipótesis $H_0 : \gamma = 0$ en el [modelo de salto en la media](#), dado por:

$$Y_j = \mathbf{x}_j^\top \boldsymbol{\beta} + d_j \gamma + \epsilon_j, \quad j = 1, \dots, n,$$

donde $d_j = 1$ si $j = i$ y 0 en caso contrario.

El modelo puede ser escrito como:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{d}_i \gamma + \boldsymbol{\epsilon},$$

con $\mathbf{d}_i = (0, 1, 0)^\top$ con un cero en la i -ésima posición.

Lo anterior permite notar que $t_i \sim t(n - p - 1)$, y de este modo,

$$E(t_i) = 0, \quad \text{var}(t_i) = \frac{n - p - 1}{n - p - 3} \approx 1$$



Objetivo:

Evaluar desvios de normalidad de los residuos studentizados t_i 's.²

Notación:

Considere $Z_i = t_i$, para $i = 1, \dots, n$

Idea:

Comparar la CDF muestral para los Z_i 's contra la CDF de la $N(0, 1)$.

Asuma que los **residuos** Z_i están ordenados

$$Z_{(1)} \leq Z_{(2)} \leq \dots \leq Z_{(n)},$$

los $Z_{(i)}$ son los cuantiles de la CDF muestral, definida como

$$\text{Proportion}(Z \leq Z_{(i)}) = \frac{i}{n}$$

²La descripción es válida otras medidas de interés.

QQ-plot en regresión lineal

Asuma que los **residuos** Z_i están ordenados

$$Z_{(1)} \leq Z_{(2)} \leq \cdots \leq Z_{(n)},$$

los $Z_{(i)}$ son los cuantiles de la CDF muestral, definida como

$$\text{Proportion}(Z \leq Z_{(i)}) = \frac{i}{n}.$$

Los cuantiles de la distribución teórica, son dados por:

$$q_i^* = \Phi^{-1}\left(\frac{i}{n}\right).$$

Si los errores son aproximadamente normales, se debe tener que el gráfico de los pares $(q_1^*, Z_{(1)}), \dots, (q_n^*, Z_{(n)})$ sea a recta identidad.



Se ha sugerido la siguiente aproximación para la esperanza de los estadísticos de orden desde $N(0, 1)$ como:

$$q_i = \Phi^{-1}\left(\frac{i - 3/8}{n + 1/4}\right),$$

de este modo, se utilizará el gráfico cuantil-cuantil (QQ-plot) de los pares $(q_i, Z_{(i)})$.

Observación:

- ▶ Podemos construir QQ-plots para diversas distribuciones.³
- ▶ Es difícil chequear visualmente desvios de la distribución de interés.

³Por ejemplo, χ^2 , t de Student, Poisson, Gama, etc.



QQ-plot con envelopes en regresión lineal

Envelopes simulados son herramientas gráficas para chequear el ajuste de un modelo. Atkinson (1985)⁴ sugirió usar el siguiente procedimiento:

- ▶ Ajustar un modelo de regresión lineal, calcular residuos y estandarizar para obtener varianza unitaria.
- ▶ Generar M (≈ 1000) muestras como respuesta. Para cada muestra ajuste el mismo modelo y calcule los residuos estandarizados
- ▶ Ordenar todos los conjuntos de residuos estandarizados.
- ▶ El envelope consiste de los cuantiles 2.5% inferior y superior de los residuos estandarizados generados en cada posición.

⁴Plots, Transformations and Regressions, Oxford University Press.



QQ-plot con envelopes en regresión lineal⁵

```
envel.norm <- function(object, nsamples = 1000, alpha = 0.05) {  
  x <- model.matrix(object)  
  n <- nrow(x); p <- ncol(x)  
  H <- x %*% solve(crossprod(x), t(x))  
  ti <- rstudent(object)  
  Id <- diag(n)  
  epsilon <- matrix(0, n, nsamples)  
  e <- matrix(0, n, nsamples)  
  e1 <- e2 <- numeric(n)  
  for (i in 1:nsamples) {  
    epsilon[,i] <- rnorm(n)  
    e[,i] <- (Id - H) %*% epsilon[,i]  
    u <- diag(Id - H)  
    e[,i] <- e[,i] / sqrt(u)  
    e[,i] <- sort(e[,i])  
  }  
  for (i in 1:n) {  
    eo <- quantile(e[i,], c(alpha / 2, 1 - alpha / 2))  
    e1[i] <- eo[1]; e2[i] <- eo[2]  
  }  
  res <- structure(list(res = sort(ti), elim = cbind(e1,e2)),  
                   label = deparse(object$call$formula))  
  class(res) <- "envelope"  
  res  
}
```

⁵Versión preliminar, no recomendable para n "grande".



QQ-plot con envelopes en regresión lineal

```
envelope <- function(object, nsamples = 1000, alpha = 0.05) {  
  n <- length(r <- resid(object))  
  p <- length(coef(object))  
  Y <- scale(qr.resid(qr(model.matrix(object)),  
                    matrix(rnorm(n * nsamples), n, nsamples)),  
            F, T) * sqrt((n - 1) / (n - p))  
  Y[,] <- Y[order(col(Y), Y)]  
  Y <- matrix(Y[order(row(Y), Y)], nsamples, n)  
  x0 <- quantile(1:nsamples, c(alpha / 2, 1 - alpha / 2))  
  if (all(x0 %% 1 == 0)) elim <- t(Y[x0,])  
  else {  
    x1 <- c(floor(x0), ceiling(x0))  
    elim <- cbind(Y[x1[1],] + (Y[x1[3],] - Y[x1[1],]) /  
                  (x1[3] - x1[1]) * (x0[1] - x1[1]),  
                  Y[x1[2],] + (Y[x1[4],] - Y[x1[2],]) /  
                  (x1[4] - x1[2]) * (x0[2] - x1[2]))  
  }  
  res <- sort(r)  
  res <- res / sqrt(sum(res^2) / (n - p))  
  res <- structure(list(res = res, elim = elim),  
                  label = deparse(object$call$formula))  
  class(res) <- "envelope"  
  res  
}
```



QQ-plot con envelopes en regresión lineal

```
plot.envelope <- function(x, ...) {  
  n <- length(x$res)  
  ylim <- range(x$res[c(1,n)], x$elim[c(1,n),])  
  nscores <- qnorm(ppoints(n))  
  oldpar <- par(pty = "s"); on.exit(par(oldpar))  
  plot(nscores, x$res, pch = 1, ylim = ylim,  
       xlab = "Normal scores", ylab = "Sorted residuals",  
       main = attr(x, "label"))  
  lines(nscores, x$elim[,1]); lines(nscores, x$elim[,2])  
  invisible(x)  
}  
  
print.envelope <- function(x, ...) {  
  lo <- x$res < x$elim[,1]  
  hi <- x$res > x$elim[,2]  
  flash <- rep("", length(lo))  
  flash[lo] <- "<"; flash[hi] <- ">"  
  if (any(lo | hi))  
    print(cbind(do.call("data.frame", x), flash = flash)[lo | hi,])  
  else cat("All points within envelope\n")  
  invisible(x)  
}
```



Herencia de la estatura (Weisberg, 2005)

Ejemplo (Herencia de la estatura):

Se recolectó la altura de $n = 1375$ madres en UK (bajo 65 años) y una de sus hijas adultas (sobre 18 años).

Cargamos el conjunto de datos y hacemos un gráfico:

```
> load("Heights.rda") # carga datos
> plot(dheight ~ mheight, data = Heights)
```

Ajuste de un modelo de regresión lineal simple

```
> fm <- lm(dheight ~ mheight, data = Heights)
> fm
```

Call:


```
lm(formula = dheight ~ mheight, data = Heights)
```

Coefficients:


(Intercept)	mheight
29.9174	0.5417



Herencia de la estatura



(a) datos estatura



(b) recta ajustada

Herencia de la estatura (Weisberg, 2005)

```
# interpreta script y ejecuta función 'envelope'
> source("envelope.lm.R")
> z <- envelope(fm)


# Salida
> z
```

	res	elim.1	elim.2	flash
3	-2.9772192	-2.9389051	-2.4155563	<
194	-2.8837417	-2.8506620	-2.3725540	<
83	-2.8469003	-2.7768534	-2.3403934	<
81	-1.9256830	-2.1707912	-1.9326915	>
187	-1.9165152	-2.1591549	-1.9192914	>
...				
72	-1.7160276	-1.9010945	-1.7197547	>
997	0.7475798	0.7478225	0.8319662	<
1000	0.7493793	0.7494135	0.8349166	<


```
# calcula QQ-plots: paneles (a) y (b)
> plot(fm, which = 2)
> plot(z)
```



Herencia de la estatura




(a) QQ-plot



(b) envelope

Datos de Concha y Toro (Osorio y Galea, 2006)⁶

Rentabilidades mensuales de Concha y Toro vs. IPSA, ajustados por bonos de interés del Banco Central entre marzo/1990 a abril/1999.



⁶Statistical Papers 47, 31-38

```
# carga biblioteca 'heavy' y datos 'CyT'
> library(heavy)
> data(cyt)
> fm <- lm(formula = CyT ~ IPSA, data = cyt)
> fm

Call:
lm(formula = CyT ~ IPSA, data = cyt)

Coefficients:
(Intercept)          IPSA
    0.01294         0.88840

# gráfico de CyT con ajuste
> plot(formula = CyT ~ IPSA, data = cyt)
> abline(coef(fm), lwd = 2, lty = 2, col = "red")

# calculo de QQ-plots
> plot(fm, which = 2)
> z <- envelope(fm)
> plot(z)
```



Datos de Concha y Toro

71 observaciones (de 110) fuera de los límites!

> z


	res	elim.1	elim.2	flash
21	-1.734317225	-3.436526273	-1.9634593	>
27	-1.415056927	-2.788774059	-1.7887230	>
100	-1.404756702	-2.419605631	-1.6748655	>
50	-1.324027912	-2.210958830	-1.5721054	>
54	-1.169203402	-2.054624463	-1.4703409	>
51	-1.153477009	-1.934805526	-1.3798186	>
11	-1.096119396	-1.838246685	-1.3320742	>
47	-1.070881256	-1.742209010	-1.2793535	>
26	-1.007932910	-1.660524800	-1.2222670	>
46	-0.957413175	-1.585646847	-1.1571871	>
22	-0.939792570	-1.516926733	-1.1140743	>
40	-0.936821200	-1.471364845	-1.0692352	>
42	-0.904023872	-1.396710446	-1.0331150	>
64	-0.875677184	-1.345638331	-0.9933418	>
24	-0.866049026	-1.284654537	-0.9480642	>
9	-0.828768419	-1.236817210	-0.9129081	>

...


25	3.757662579	1.787389608	2.7912823	>
12	6.047936818	1.950943630	3.4974732	>



Datos de Concha y Toro




(a) datos Concha y Toro




(b) recta ajustada

Datos de Concha y Toro



(a) QQ-plot



(b) envelope

Leverages en regresión lineal

Tenemos que

$$\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}, \quad \mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top. \quad (1)$$

Es fácil notar que,

$$\hat{Y}_i = \sum_{j=1}^n h_{ij} Y_j = h_{ii} Y_i + \sum_{j \neq i} h_{ij} Y_j, \quad (2)$$

es decir el **valor predicho** es una combinación lineal de las respuestas observadas con pesos dados por los elementos de la matriz de proyección \mathbf{H} .

La matriz \mathbf{H} tiene las siguientes propiedades:

Propiedad 1:

\mathbf{H} es simétrica e idempotente con $\text{rg}(\mathbf{H}) = \text{tr}(\mathbf{H}) = p$.



Propiedad 2:

Los elementos diagonales de \mathbf{H} están acotados como:

$$0 \leq h_{ii} \leq 1, \quad i = 1, \dots, n.$$

En efecto, desde

$$\hat{\mathbf{Y}} \sim \mathbf{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{H}), \quad \mathbf{e} \sim \mathbf{N}(\mathbf{0}, \sigma^2 (\mathbf{I} - \mathbf{H})).$$

De este modo,

$$\text{var}(\hat{Y}_i) = \sigma^2 h_{ii}, \quad \text{var}(e_i) = \sigma^2 (1 - h_{ii}),$$

de ahí que obtenemos el resultado.

Para otra demostración, ver [Resultado A.6](#) desde el Apéndice A de las notas de clase.



Propiedad 3:

Tenemos,

$$h_{ii} = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i, \quad i = 1, \dots, n.$$

Además,

$$\bar{h} = \frac{1}{n} \sum_{i=1}^n h_{ii} = \frac{1}{n} \text{tr}(\mathbf{H}) = \frac{p}{n}.$$

Propiedad 4:

Sea $\widetilde{\mathbf{X}}$ la matriz de datos centrados. En este caso, los elementos diagonales de $\widetilde{\mathbf{H}}$ están dados por

$$\widetilde{h}_{ii} = (\mathbf{x}_i - \bar{\mathbf{x}})^\top (\widetilde{\mathbf{X}}^\top \widetilde{\mathbf{X}})^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}), \quad i = 1, \dots, n.$$

Luego \widetilde{h}_{ii} es la distancia ponderada desde \mathbf{x}_i al **centroide** $\bar{\mathbf{x}}$.



Observación:

Hoaglin y Welsch (1978)⁷ sugieren que aquellas observaciones que exceden dos veces su promedio

$$h_{ii} > 2p/n \quad (= 2\bar{h})$$

indican un alto leverage. Mientras que Huber (1981)⁸ sugirió identificar observaciones tal que

$$h_{ii} > 0.5,$$

independiente de n o p .

En la práctica se debe prestar atención a casos inusualmente grandes **con relación al resto** de h_{ii} 's.

⁷The American Statistician **32**, 17-22.

⁸Robust Statistics. Wiley, New York.



Propiedad 5:

Desde Ecuación (1), sigue que

$$\frac{\partial \hat{\mathbf{Y}}}{\partial \mathbf{Y}^\top} = \mathbf{H},$$

y en particular $\partial \hat{Y}_i / \partial Y_i = h_{ii}$, para $i = 1, \dots, n$.

Propiedad 6:

Si el modelo **tiene intercepto**, entonces $\mathbf{H}\mathbf{1} = \mathbf{1}$.

Considere $\mathbf{X} = (\mathbf{1}, \mathbf{X}_1)$. Sabemos que $\mathbf{H}\mathbf{X} = \mathbf{X}$, y de ahí que

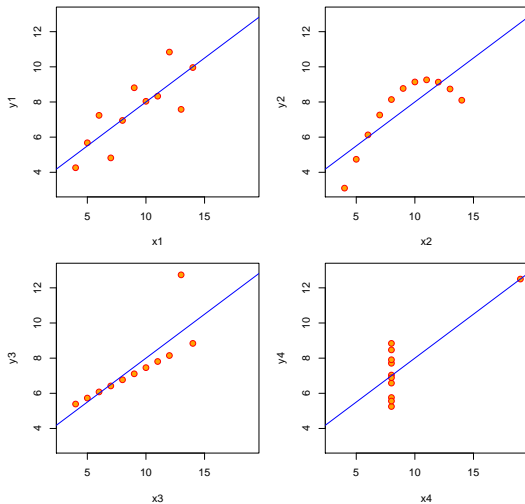
$$\mathbf{H}(\mathbf{1}, \mathbf{X}_1) = (\mathbf{1}, \mathbf{X}_1),$$

y el resultado sigue.




Cuarteto de regresiones “idénticas” de Anscombe (1973)

Anscombe's 4 Regression data sets



Leverages: Datos de Anscombe

Leverage plots. Anscombe's data sets



Leverages: Datos de Concha y Toro

```
# ajuste de datos 'CyT', almacenando 'x'
> fm <- lm(CyT ~ IPSA, data = cyt, x = TRUE)
> x <- fm$x # extrae 'x'
> z <- influence(fm)
> attributes(z)
$names
[1] "hat"      "coefficients"  "sigma"      "wt.res"

# extrae 'leverages' y calcula punto de corte
> hats <- z$hat
> n <- nrow(x)
> p <- ncol(x)
> cutoff <- 2 * p / n

> which <- hats > cutoff
> idx <- 1:n
> obs <- idx[which]

# gráfico de leverages con punto de corte
> plot(z$hat, ylim = c(0,0.18), ylab = "Leverages")
> abline(h = cutoff, lwd = 2, lty = 2, col = "red")
> text(obs, hat[obs], labels = as.character(obs), pos = 3)

# otros métodos para calcular leverages
> hats <- hatvalues(fm)
> hats <- hat(x, intercept = FALSE)
```



Leverages: Datos de Concha y Toro

