

# MAT-266: Métodos resistentes a outliers en regresión, distribuciones con colas pesadas

Felipe Osorio

[fosorios.mat.utfsm.cl](mailto:fosorios.mat.utfsm.cl)

Departamento de Matemática, UTFSM



## Observación:

Debemos resaltar que **diferentemente** al caso de la **distribución normal**, en el caso general de la familia elíptica, podemos tener los siguientes enfoques:

- (a) **Modelo dependiente:** Supondremos  $Y_1, \dots, Y_n$  tal que su **densidad conjunta**  $\mathbf{Y} = (Y_1, \dots, Y_n)^\top \sim \text{EC}_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n; g)$ , sigue una distribución de contornos elípticos.<sup>1</sup>
- (b) **Modelo independiente:** Considere  $Y_1, \dots, Y_n$  variables aleatorias **independientes** cada una con distribución  $\text{EC}_1(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; g)$ .

---

<sup>1</sup>El estimador de  $\boldsymbol{\beta}$  en el modelo dependiente es equivalente al LSE y por tanto NO es robusto.



En la siguientes diapositivas asumiremos el **modelo independiente**,

$$Y_i \stackrel{\text{ind}}{\sim} \text{EC}_1(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; g), \quad i = 1, \dots, n,$$

donde

$$f(y_i; \boldsymbol{\theta}) = \frac{1}{\sigma} g((Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 / \sigma^2),$$

con  $\boldsymbol{\theta} = (\boldsymbol{\beta}^\top, \sigma^2)^\top$ , y la función generadora de densidades  $g$  debe satisfacer:

$$\int_0^\infty u^{-1/2} g(u) \, du < +\infty.$$



## Estimación ML bajo la familia de contornos elípticos

Para obtener los **estimadores máximo verosímiles** de  $\beta$  y  $\sigma^2$  asumiremos que  $g(\cdot)$  es conocido. La función de log-verosimilitud adopta la forma:

$$\ell(\theta) = -\frac{n}{2} \log \sigma^2 + \sum_{i=1}^n \log g(u_i),$$

donde  $u_i = (Y_i - \mathbf{x}_i^\top \beta)^2 / \sigma^2$ , para  $i = 1, \dots, n$ . Diferenciando  $\ell(\theta)$  con relación a  $\beta$ , obtenemos

$$\begin{aligned} d_\beta \ell(\theta) &= \sum_{i=1}^n d_\beta \log g(u_i) = \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} d_\beta u_i \\ &= -\frac{2}{\sigma^2} \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} (Y_i - \mathbf{x}_i^\top \beta) \mathbf{x}_i^\top d\beta \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n W_i(\theta) (Y_i - \mathbf{x}_i^\top \beta) \mathbf{x}_i^\top d\beta \end{aligned}$$

donde  $W_i(\theta) = -2g'(u_i)/g(u_i)$ , para  $i = 1, \dots, n$ .



Análogamente, diferenciando  $\ell(\boldsymbol{\theta})$  con relación a  $\sigma^2$ , tenemos

$$\begin{aligned}d_{\sigma^2} \ell(\boldsymbol{\theta}) &= -\frac{n}{2\sigma^2} d\sigma^2 + \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} d_{\sigma^2} u_i \\&= -\frac{n}{2\sigma^2} d\sigma^2 - \frac{1}{\sigma^4} \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta}) d\sigma^2 \\&= -\frac{n}{2\sigma^2} d\sigma^2 + \frac{1}{2\sigma^4} \sum_{i=1}^n W_i(\boldsymbol{\theta}) (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta}) d\sigma^2 \\&= -\frac{n}{2\sigma^2} d\sigma^2 + \frac{1}{2\sigma^4} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) d\sigma^2\end{aligned}$$

donde

$$\mathbf{W} = \text{diag} (W_1(\boldsymbol{\theta}), \dots, W_n(\boldsymbol{\theta})).$$

# Estimación ML bajo la familia de contornos elípticos

La condición de primer orden, lleva al siguiente **sistema de ecuaciones**:

$$\begin{aligned}\mathbf{X}^\top \widehat{\mathbf{W}}(\mathbf{Y} - \mathbf{X}\widehat{\boldsymbol{\beta}}) &= \mathbf{0}, \\ \widehat{\sigma}^2 &= \frac{1}{n}(\mathbf{Y} - \mathbf{X}\widehat{\boldsymbol{\beta}})^\top \widehat{\mathbf{W}}(\mathbf{Y} - \mathbf{X}\widehat{\boldsymbol{\beta}}),\end{aligned}$$

que **no** tiene solución en **forma explícita** y por tanto **métodos iterativos son requeridos**.

Por ejemplo, usando una estimación inicial  $\boldsymbol{\theta} = \boldsymbol{\theta}^{(k)}$ , actualizamos las estimaciones para  $\boldsymbol{\beta}$  y  $\sigma^2$ , como:

$$\begin{aligned}\boldsymbol{\beta}^{(k+1)} &= (\mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{Y}, \\ \sigma^{2(k+1)} &= \frac{1}{n}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}^{(k)})^\top \mathbf{W}^{(k)}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}^{(k)}),\end{aligned}$$

a la convergencia del algoritmo<sup>2</sup>, hacemos  $(\widehat{\boldsymbol{\beta}}, \widehat{\sigma}^2)$ .

---

<sup>2</sup>Esto es, cuando la secuencia  $\{\boldsymbol{\beta}^{(k)}, \sigma^{2(k)}\}$  se 'estabiliza'.



## Funciones de pesos $W(\theta)$ para algunas distribuciones elípticas

- **Normal:**  $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2)$ , tenemos:

$$W_i(\boldsymbol{\theta}) = 1, \quad i = 1, \dots, n.$$

- **t-Student:**  $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} t(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$ ,  $\nu > 0$ ,

$$W_i(\boldsymbol{\theta}) = \frac{\nu + 1}{\nu + u_i}, \quad i = 1, \dots, n,$$

la distribución Cauchy( $\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2$ ), es obtenida para  $\nu = 1$ .

- **Normal contaminada:**  $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} \text{CN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \epsilon, \gamma)$ , con  $\epsilon \in [0, 1)$  y  $\gamma > 0$ ,


$$W_i(\boldsymbol{\theta}) = \frac{(1 - \epsilon) \exp(-u/2) + \epsilon \gamma^{-3/2} \exp(-u/(2\gamma))}{(1 - \epsilon) \exp(-u/2) + \epsilon \gamma^{-1/2} \exp(-u/(2\gamma))}, \quad i = 1, \dots, n.$$

- **Exponencial Potencia:**  $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} \text{PE}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \lambda)$ ,  $\lambda > 0$ ,


$$W_i(\boldsymbol{\theta}) = \lambda u_i^{\lambda-1}, \quad i = 1, \dots, n.$$




# Funciones de influencia para algunas distribuciones elípticas




(a)  $t$  de Student,  $\nu = 4$



(b) CN,  $\epsilon = 0.05$ ,  $\gamma = 10$



(c) PE,  $\lambda = 0.6$



(d) PE,  $\lambda = 0.5$



Sea  $Y_1, \dots, Y_n$  variable aleatorias independientes con distribución  $\text{SMN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; H)$  cada una con densidad

$$f(y_i; \boldsymbol{\theta}) = (2\pi\sigma)^{-1/2} \int_0^\infty \omega^{1/2} \exp(-\omega u_i/2) dH(\omega),$$

donde  $u_i = (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 / \sigma^2$ ,  $i = 1, \dots, n$ .

### *Observación:*

Una variable aleatoria  $Y_i \sim \text{SMN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; H)$ , admite la representación:

$$Y_i | W = \omega \sim N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2 / \omega), \quad W \sim H(\boldsymbol{\delta}),$$

lo que permite abordar la estimación ML usando el algoritmo EM.



### *Ejemplo: Distribución Slash*

Una variable aleatoria  $Y_i$  tiene distribución **Slash** si su función de densidad es de la forma:

$$f(y_i) = \nu(2\pi\sigma^2)^{-1/2} \int_0^1 \omega^{\nu-1/2} \exp(-\omega u/2) d\omega.$$

Tenemos que  $h(\omega) = \nu\omega^{\nu-1}$ , para  $\omega \in (0, 1)$  y  $\nu > 0$ . Es decir,  $W \sim \text{Beta}(\nu, 1)$ .

### *Ejemplo: Distribución t de Student*

Para  $Y_i \sim t(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$ , con  $\nu > 0$ , podemos escribir

$$Y_i|W \sim N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2/\omega), \quad W \sim \text{Gamma}(\nu/2, \nu/2),$$

es decir,

$$h(\omega; \nu) = \frac{(\nu/2)^{\nu/2} \omega^{\nu/2-1}}{\Gamma(\nu/2)} \exp(-\nu\omega/2).$$



# Algoritmo EM (Esperanza-Maximización)

## *Consideraciones:*

- ▶ Algoritmo para el cálculo iterativo de **estimadores ML** en modelos con **datos incompletos**.
- ▶ Requiere de una **formulación de datos aumentados**.
- ▶ Reemplaza una optimización **“compleja”** (estimación ML) por una serie de maximizaciones **“simples”**.



## Formulación de datos aumentados:

Sea  $\mathbf{Y}_{\text{obs}}$  vector de **datos observados** con función de densidad  $f(\mathbf{y}_{\text{obs}}; \boldsymbol{\theta})$ .

El objetivo es aumentar los datos observados  $\mathbf{Y}_{\text{obs}}$  con variables latentes  $\mathbf{Y}_{\text{mis}}$  (**datos perdidos**). Esto es, se considera el vector de **datos completos**

$$\mathbf{Y}_{\text{com}} = (\mathbf{Y}_{\text{obs}}^{\top}, \mathbf{Y}_{\text{mis}}^{\top})^{\top},$$

tal que la densidad  $f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta})$  sea **simple**.



## Algoritmo EM (Dempster, Laird y Rubin, 1977)<sup>3</sup>

El algoritmo EM es útil cuando la función de log-verosimilitud

$$\begin{aligned}\ell_o(\boldsymbol{\theta}; \mathbf{Y}_{\text{obs}}) &= \log f(\mathbf{y}_{\text{obs}}; \boldsymbol{\theta}) \\ &= \log \int f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta}) d\mathbf{y}_{\text{mis}},\end{aligned}$$

es **difícil de maximizar directamente**.

El algoritmo EM es un **procedimiento iterativo** que permite realizar la estimación ML basandose en la **log-verosimilitud de datos completos**:

$$\ell_c(\boldsymbol{\theta}; \mathbf{Y}_{\text{com}}) = \log f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta}).$$

---

<sup>3</sup>Journal of the Royal Statistical Society, Series B **39**, 1-38.



## Algoritmo EM (Esperanza-Maximización)

El algoritmo EM permite obtener los MLE en **problemas con datos incompletos** por medio de las etapas:

*Paso E:* para  $\theta^{(k)}$  estimación de  $\theta$  en la  $k$ -ésima iteración, calcular la  $Q$ -función,

$$\begin{aligned} Q(\theta|\theta^{(k)}) &= E\{\ell_c(\theta; \mathbf{Y}_{\text{com}}) | \mathbf{Y}_{\text{obs}}, \theta^{(k)}\} \\ &= \int \ell_c(\theta; \mathbf{Y}_{\text{com}}) f(\mathbf{y}_{\text{mis}} | \mathbf{y}_{\text{obs}}; \theta^{(k)}) d\mathbf{y}_{\text{mis}}. \end{aligned} \quad (1)$$

*Paso M:* determinar  $\theta^{(k+1)}$  como

$$\theta^{(k+1)} = \arg \max_{\theta} Q(\theta|\theta^{(k)}). \quad (2)$$



# Una variante del Algoritmo EM

Dempster, Laird y Rubin (1977) definieron el **Algoritmo EM generalizado (GEM)**, mediante la siguiente modificación del paso M:

*Paso M\**: seleccionar  $\theta^{(k+1)}$  satisfaciendo,

$$Q(\theta^{(k+1)} | \hat{\theta}^{(k)}) > Q(\theta^{(k)} | \theta^{(k)}).$$

*Sugerencia*: considerar **sólo un** paso Newton en la optimización de  $Q(\theta | \theta^{(k)})$ .



## Teorema (Dempster, Laird y Rubin, 1977)

Todo algoritmo EM o GEM **incrementa la log-verosimilitud de datos observados**  $\ell_o(\boldsymbol{\theta}; \mathbf{Y}_{\text{obs}})$  en cada iteración, esto es,

$$\ell_o(\boldsymbol{\theta}^{(k+1)}; \mathbf{Y}_{\text{obs}}) \geq \ell_o(\boldsymbol{\theta}^{(k)}; \mathbf{Y}_{\text{obs}}).$$

## Convergencia (Wu, 1983; Little y Rubin, 1987)

Bajo condiciones suaves, la secuencia  $\{\boldsymbol{\theta}^{(k)}\}_{k \geq 0}$  generada por el algoritmo EM (GEM). **Converge a un punto estacionario** de  $\ell_o(\boldsymbol{\theta}; \mathbf{Y}_{\text{obs}})$ .





## *Propiedades del algoritmo EM:*

- ▶ Frecuentemente el algoritmo EM es **simple**, de **bajo costo** computacional y numéricamente **estable**.
- ▶ Dempster, Laird y Rubin (1977) mostraron que el algoritmo EM converge con **velocidad lineal**, que depende de la **proporción** de información perdida.<sup>4</sup>
- ▶ Para modelos con datos aumentados con densidad en la **familia exponencial**, el algoritmo EM reduce a **actualizar** las estadísticas suficientes.
- ▶ Errores estándar pueden ser obtenidos por cálculo directo, diferenciación numérica o usando el **Principio de Información Perdida** (Louis, 1982).

---

<sup>4</sup> puede ser **extremadamente** lento.



Sea  $Y_1, \dots, Y_n$  variables aleatorias independientes  $\text{SMN}(\mathbf{x}_i\boldsymbol{\beta}, \sigma^2; \mathbf{H})$ . Se llevará a cabo la **estimación ML** usando el **algoritmo EM**.

De este modo, tenemos el siguiente **modelo jerárquico**:

$$Y_i|W_i \sim \text{N}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2/\omega_i), \quad W_i \sim \text{H}(\boldsymbol{\delta}), \quad i = 1, \dots, n.$$

En este caso el vector de **datos completos** es  $\mathbf{Y}_{\text{com}} = (\mathbf{Y}^\top, \boldsymbol{\omega}^\top)^\top$ , donde

$$\mathbf{Y} = (Y_1, \dots, Y_n)^\top, \quad \boldsymbol{\omega} = (\omega_1, \dots, \omega_n)^\top.$$

En este contexto,  $\mathbf{Y}$  corresponde a los **datos observados**, mientras que  $\boldsymbol{\omega}$  serán asumidos como **datos perdidos**.



Asuma  $\delta$  conocido, la función de log-verosimilitud de datos completos adopta la forma:

$$\begin{aligned}\ell_c(\boldsymbol{\theta}; \mathbf{y}_{\text{com}}) &= \log f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta}) = \sum_{i=1}^n \log f(y_i, \omega_i; \boldsymbol{\theta}) \\ &= \sum_{i=1}^n \log f(y_i | \omega_i; \boldsymbol{\theta}) + \sum_{i=1}^n \log h(\omega_i; \boldsymbol{\delta}) \\ &= -\frac{n}{2} \log 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n \omega_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 - \frac{1}{2} \sum_{i=1}^n \log \omega_i + \log h^{(n)}(\boldsymbol{\omega}; \boldsymbol{\delta}),\end{aligned}$$

donde  $h^{(n)}(\boldsymbol{\omega}; \boldsymbol{\delta})$  denota la densidad conjunta para las variables de mezcla  $\boldsymbol{\omega} = (\omega_1, \dots, \omega_n)^\top$ .



## Estimación ML usando mezclas de escala normal

Considere una estimación para  $\theta = \theta^{(k)}$ , entonces

$$Q(\theta; \theta^{(k)}) = E\{\ell_c(\theta; \mathbf{y}_{\text{com}}) | \mathbf{y}; \theta^{(k)}\} = Q_1(\beta, \sigma^2; \theta^{(k)}) + Q_2(\delta; \theta^{(k)}),$$

donde

$$Q_1(\beta, \sigma^2; \theta^{(k)}) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \omega_i^{(k)} (Y_i - \mathbf{x}_i^\top \beta)^2,$$

$$Q_2(\delta; \theta^{(k)}) = E\{\log h^{(n)}(\omega; \delta) | \mathbf{y}; \theta^{(k)}\},$$

con  $\omega_i^{(k)} = E(\omega_i | \mathbf{x}_i; \theta^{(k)})$  para  $i = 1, \dots, n$ . En general, la forma para la esperanza condicional requerida en el paso-E del algoritmo EM es dada por:

$$E(\omega_i | \mathbf{x}_i; \theta) = \frac{\int_0^\infty \omega_i^{3/2} \exp(-\omega_i u_i / 2) dH(\delta)}{\int_0^\infty \omega_i^{1/2} \exp(-\omega_i u_i / 2) dH(\delta)},$$

con  $u_i = (Y_i - \mathbf{x}_i^\top \beta)^2 / \sigma^2$ ,  $i = 1, \dots, n$ .



- **t-Student:**  $Y_i \stackrel{\text{ind}}{\sim} t(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$ ,  $i = 1, \dots, n$ , en cuyo caso

$$E(\omega_i | Y_i; \boldsymbol{\theta}) = \frac{\nu + 1}{\nu + u_i}.$$

- **Slash:**  $Y_i \stackrel{\text{ind}}{\sim} \text{Slash}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$ , para  $i = 1, \dots, n$ . De este modo,

$$E(\omega_i | Y_i; \boldsymbol{\theta}) = \left( \frac{2\nu + 1}{u_i} \right) \frac{P_1(\nu + 3/2, u_i/2)}{P_1(\nu + 1/2, u_i/2)},$$

donde

$$P_z(a, b) = \frac{b^a}{\Gamma(a)} \int_0^z t^{a-1} e^{-bt} dt,$$

es la función gama incompleta (regularizada).

- **Exponencial Potencia:**  $Y_i \stackrel{\text{ind}}{\sim} \text{PE}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \lambda)$ ,  $i = 1, \dots, n$ , donde

$$E(\omega_i | Y_i; \boldsymbol{\theta}) = \lambda u_i^{\lambda-1}, \quad u_i \neq 0, \lambda \in (0, 1].$$



## Estimación ML usando mezclas de escala normal

Finalmente, el algoritmo EM obtener los MLE en el modelo

$$Y_i \stackrel{\text{ind}}{\sim} \text{SMN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; \mathbf{H}), \quad i = 1, \dots, n,$$

adopta la forma:

*Paso E:* para  $\boldsymbol{\theta}^{(k)}$ , calcular:

$$\omega_i^{(k)} = \mathbb{E}(\omega_i | Y_i; \boldsymbol{\theta}^{(k)}), \quad i = 1, \dots, n.$$

*Paso M:* actualizar  $\boldsymbol{\beta}^{(k+1)}$  y  $\sigma^{2(k+1)}$  como:

$$\begin{aligned} \boldsymbol{\beta}^{(k+1)} &= (\mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{Y} \\ \sigma^{2(k+1)} &= \frac{1}{n} (\mathbf{Y} - \mathbf{X} \boldsymbol{\beta}^{(k)})^\top \mathbf{W}^{(k)} (\mathbf{Y} - \mathbf{X} \boldsymbol{\beta}^{(k)}), \end{aligned}$$

donde  $\mathbf{W}^{(k)} = \text{diag}(\omega_1(\boldsymbol{\theta}^{(k)}), \dots, \omega_n(\boldsymbol{\theta}^{(k)}))$ .

A la convergencia del algoritmo hacemos  $\boldsymbol{\beta} = \hat{\boldsymbol{\beta}}$  y  $\sigma^2 = \hat{\sigma}^2$ .



# Llamadas telefónicas en Bélgica 1950-1973

```
# carga datos de llamadas
> library(MASS)
> data(phones)

# carga biblioteca 'heavy'
> library(heavy)

# Ajuste usando distribución Cauchy
> fm <- heavyLm(calls ~ year, data = phones, family = Cauchy())

# Salida
> fm
Call:
heavyLm(formula = calls ~ year, data = phones, family = Cauchy())
Converged in 85 iterations

Coefficients:
(Intercept)          year
   -53.8761         1.1229

Degrees of freedom: 24 total; 22 residual
Scale estimate: 1.394029
```



# Llamadas telefónicas en Bélgica 1950-1973

```
# Salida
> summary(fm)
Linear model under heavy-tailed distributions
Data: phones; Family: Cauchy()

Residuals:
    Min       1Q   Median       3Q      Max
-1.848  -0.213   0.319  38.959 188.397

Coefficients:
              Estimate Std. Error Z value  p-value
(Intercept) -53.8761    3.0473  -17.6801   0.0000
year          1.1229    0.0492   22.8051   0.0000

Degrees of freedom: 24 total; 22 residual
Scale estimate: 1.394029
Log-likelihood: -102.28 on 3 degrees of freedom

# 'pesos' estimados
> fm$weights
[1] 0.4694 0.8970 1.9514 1.9051 1.9642 1.6087 1.2597 0.8829 1.5338
[10] 1.8178 2.0000 1.8932 1.8320 0.1381 0.0003 0.0003 0.0002 0.0001
[19] 0.0001 0.0001 0.0083 0.5796 1.9988 1.2589
```





## Llamadas telefónicas en Bélgica 1950-1973

```
# Estimando los 'grados de libertad'
> fm <- heavyLm(calls ~ year, data = phones, family = Student(df = 4))
> fm
Call:
heavyLm(formula = calls ~ year, data = phones,
        family = Student(df = 0.35881))
Converged in 170 iterations


Coefficients:
(Intercept)          year
   -54.0142         1.1260

Degrees of freedom: 24 total; 22 residual
Scale estimate: 0.2661921


# 'pesos' estimados
> fm$weights
[1] 0.0791 0.2057 2.9578 2.3797 2.7616 0.7649 0.3692 0.1843 0.6294
[10] 1.3377 3.7112 2.4381 1.9253 0.0197 0.0000 0.0000 0.0000 0.0000
[19] 0.0000 0.0000 0.0011 0.0947 3.6673 0.4728
```



# Llamadas telefónicas en Bélgica 1950-1973




(a) normal




(b) Student,  $\hat{\nu} = 0.3588$

# Llamadas telefónicas en Bélgica 1950-1973



(a) Cauchy



(b) Student,  $\hat{\nu} = 0.3588$