

MAT-266: Métodos resistentes a outliers en regresión, distribuciones con colas pesadas

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Observación:

Debemos resaltar que **diferentemente** al caso de la **distribución normal**, en el caso general de la familia elíptica, podemos tener los siguientes enfoques:

- (a) **Modelo dependiente:** Supondremos Y_1, \dots, Y_n tal que su **densidad conjunta** $\mathbf{Y} = (Y_1, \dots, Y_n)^\top \sim EC_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n; g)$, sigue una distribución de contornos elípticos.¹
- (b) **Modelo independiente:** Considere Y_1, \dots, Y_n variables aleatorias **independientes** cada una con distribución $EC_1(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; g)$.

¹El estimador de $\boldsymbol{\beta}$ en el modelo dependiente es equivalente al LSE y por tanto NO es robusto.



En la siguientes diapositivas asumiremos el **modelo independiente**,

$$Y_i \stackrel{\text{ind}}{\sim} \text{EC}_1(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; g), \quad i = 1, \dots, n,$$

donde

$$f(y_i; \boldsymbol{\theta}) = \frac{1}{\sigma} g((Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 / \sigma^2),$$

con $\boldsymbol{\theta} = (\boldsymbol{\beta}^\top, \sigma^2)^\top$, y la función generadora de densidades g debe satisfacer:

$$\int_0^\infty u^{-1/2} g(u) \, du < +\infty.$$



Estimación ML bajo la familia de contornos elípticos

Para obtener los **estimadores máximo verosímiles** de β y σ^2 asumiremos que $g(\cdot)$ es conocido. La función de log-verosimilitud adopta la forma:

$$\ell(\theta) = -\frac{n}{2} \log \sigma^2 + \sum_{i=1}^n \log g(u_i),$$

donde $u_i = (Y_i - \mathbf{x}_i^\top \beta)^2 / \sigma^2$, para $i = 1, \dots, n$. Diferenciando $\ell(\theta)$ con relación a β , obtenemos

$$\begin{aligned} d_\beta \ell(\theta) &= \sum_{i=1}^n d_\beta \log g(u_i) = \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} d_\beta u_i \\ &= -\frac{2}{\sigma^2} \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} (Y_i - \mathbf{x}_i^\top \beta) \mathbf{x}_i^\top d\beta \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n W_i(\theta) (Y_i - \mathbf{x}_i^\top \beta) \mathbf{x}_i^\top d\beta \end{aligned}$$

donde $W_i(\theta) = -2g'(u_i)/g(u_i)$, para $i = 1, \dots, n$.



Estimación ML bajo la familia de contornos elípticos

Análogamente, diferenciando $\ell(\boldsymbol{\theta})$ con relación a σ^2 , tenemos

$$\begin{aligned} d_{\sigma^2} \ell(\boldsymbol{\theta}) &= -\frac{n}{2\sigma^2} d\sigma^2 + \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} d_{\sigma^2} u_i \\ &= -\frac{n}{2\sigma^2} d\sigma^2 - \frac{1}{\sigma^4} \sum_{i=1}^n \frac{g'(u_i)}{g(u_i)} (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 d\sigma^2 \\ &= -\frac{n}{2\sigma^2} d\sigma^2 + \frac{1}{2\sigma^4} \sum_{i=1}^n W_i(\boldsymbol{\theta}) (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 d\sigma^2 \\ &= -\frac{n}{2\sigma^2} d\sigma^2 + \frac{1}{2\sigma^4} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) d\sigma^2 \end{aligned}$$

donde

$$\mathbf{W} = \text{diag} (W_1(\boldsymbol{\theta}), \dots, W_n(\boldsymbol{\theta})).$$



Estimación ML bajo la familia de contornos elípticos

La condición de primer orden, lleva al siguiente **sistema de ecuaciones**:

$$\begin{aligned}\mathbf{X}^\top \widehat{\mathbf{W}}(\mathbf{Y} - \mathbf{X}\widehat{\boldsymbol{\beta}}) &= \mathbf{0}, \\ \widehat{\sigma}^2 &= \frac{1}{n}(\mathbf{Y} - \mathbf{X}\widehat{\boldsymbol{\beta}})^\top \widehat{\mathbf{W}}(\mathbf{Y} - \mathbf{X}\widehat{\boldsymbol{\beta}}),\end{aligned}$$

que **no** tiene solución en **forma explícita** y por tanto **métodos iterativos son requeridos**.

Por ejemplo, usando una estimación inicial $\boldsymbol{\theta} = \boldsymbol{\theta}^{(k)}$, actualizamos las estimaciones para $\boldsymbol{\beta}$ y σ^2 , como:

$$\begin{aligned}\boldsymbol{\beta}^{(k+1)} &= (\mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{Y}, \\ \sigma^{2(k+1)} &= \frac{1}{n}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}^{(k)})^\top \mathbf{W}^{(k)}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}^{(k)}),\end{aligned}$$

a la convergencia del algoritmo², hacemos $(\widehat{\boldsymbol{\beta}}, \widehat{\sigma}^2)$.

²Esto es, cuando la secuencia $\{\boldsymbol{\beta}^{(k)}, \sigma^{2(k)}\}$ se 'estabiliza'.



Funciones de pesos $W(\theta)$ para algunas distribuciones elípticas

- **Normal:** $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2)$, tenemos:

$$W_i(\boldsymbol{\theta}) = 1, \quad i = 1, \dots, n.$$

- **t-Student:** $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} t(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$, $\nu > 0$,

$$W_i(\boldsymbol{\theta}) = \frac{\nu + 1}{\nu + u_i}, \quad i = 1, \dots, n,$$

la distribución Cauchy($\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2$), es obtenida para $\nu = 1$.

- **Normal contaminada:** $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} \text{CN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \epsilon, \gamma)$, con $\epsilon \in [0, 1)$ y $\gamma > 0$,


$$W_i(\boldsymbol{\theta}) = \frac{(1 - \epsilon) \exp(-u/2) + \epsilon \gamma^{-3/2} \exp(-u/(2\gamma))}{(1 - \epsilon) \exp(-u/2) + \epsilon \gamma^{-1/2} \exp(-u/(2\gamma))}, \quad i = 1, \dots, n.$$

- **Exponencial Potencia:** $Y_1, \dots, Y_n \stackrel{\text{ind}}{\sim} \text{PE}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \lambda)$, $\lambda > 0$,


$$W_i(\boldsymbol{\theta}) = \lambda u_i^{\lambda-1}, \quad i = 1, \dots, n.$$




Funciones de influencia para algunas distribuciones elípticas




(a) t de Student, $\nu = 4$



(b) CN, $\epsilon = 0.05$, $\gamma = 10$



(c) PE, $\lambda = 0.6$



(d) PE, $\lambda = 0.5$

Sea Y_1, \dots, Y_n variable aleatorias independientes con distribución $\text{SMN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; H)$ cada una con densidad

$$f(y_i; \boldsymbol{\theta}) = (2\pi\sigma)^{-1/2} \int_0^\infty \omega^{1/2} \exp(-\omega u_i/2) dH(\omega),$$

donde $u_i = (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 / \sigma^2$, $i = 1, \dots, n$.

Observación:

Una variable aleatoria $Y_i \sim \text{SMN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; H)$, admite la representación:

$$Y_i | W = \omega \sim N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2 / \omega), \quad W \sim H(\boldsymbol{\delta}),$$

lo que permite abordar la estimación ML usando el algoritmo EM.



Ejemplo: Distribución Slash

Una variable aleatoria Y_i tiene distribución **Slash** si su función de densidad es de la forma:

$$f(y_i) = \nu(2\pi\sigma^1)^{-1/2} \int_0^1 \omega^{\nu-1/2} \exp(-\omega u/2) d\omega.$$

Tenemos que $h(\omega) = \nu\omega^{\nu-1}$, para $\omega \in (0, 1)$ y $\nu > 0$. Es decir, $W \sim \text{Beta}(\nu, 1)$.

Ejemplo: Distribución t de Student

Para $Y_i \sim t(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$, con $\nu > 0$, podemos escribir

$$Y_i|W \sim N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2/\omega), \quad W \sim \text{Gamma}(\nu/2, \nu/2),$$

es decir,

$$h(\omega; \nu) = \frac{(\nu/2)^{\nu/2} \omega^{\nu/2-1}}{\Gamma(\nu/2)} \exp(-\nu\omega/2).$$



Algoritmo EM (Esperanza-Maximización)

Consideraciones:

- ▶ Algoritmo para el cálculo iterativo de **estimadores ML** en modelos con **datos incompletos**.
- ▶ Requiere de una **formulación de datos aumentados**.
- ▶ Reemplaza una optimización **“compleja”** (estimación ML) por una serie de maximizaciones **“simples”**.



Formulación de datos aumentados:

Sea \mathbf{Y}_{obs} vector de **datos observados** con función de densidad $f(\mathbf{y}_{\text{obs}}; \boldsymbol{\theta})$.

El objetivo es aumentar los datos observados \mathbf{Y}_{obs} con variables latentes \mathbf{Y}_{mis} (**datos perdidos**). Esto es, se considera el vector de **datos completos**

$$\mathbf{Y}_{\text{com}} = (\mathbf{Y}_{\text{obs}}^{\top}, \mathbf{Y}_{\text{mis}}^{\top})^{\top},$$

tal que la densidad $f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta})$ sea **simple**.



Algoritmo EM (Dempster, Laird y Rubin, 1977)³

El algoritmo EM es útil cuando la función de log-verosimilitud

$$\begin{aligned}\ell_o(\boldsymbol{\theta}; \mathbf{Y}_{\text{obs}}) &= \log f(\mathbf{y}_{\text{obs}}; \boldsymbol{\theta}) \\ &= \log \int f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta}) d\mathbf{y}_{\text{mis}},\end{aligned}$$

es **difícil de maximizar directamente**.

El algoritmo EM es un **procedimiento iterativo** que permite realizar la estimación ML basandose en la **log-verosimilitud de datos completos**:

$$\ell_c(\boldsymbol{\theta}; \mathbf{Y}_{\text{com}}) = \log f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta}).$$

³Journal of the Royal Statistical Society, Series B **39**, 1-38.



Algoritmo EM (Esperanza-Maximización)

El algoritmo EM permite obtener los MLE en **problemas con datos incompletos** por medio de las etapas:

Paso E: para $\theta^{(k)}$ estimación de θ en la k -ésima iteración, calcular la Q -función,

$$\begin{aligned} Q(\theta|\theta^{(k)}) &= E\{\ell_c(\theta; \mathbf{Y}_{\text{com}}) | \mathbf{Y}_{\text{obs}}, \theta^{(k)}\} \\ &= \int \ell_c(\theta; \mathbf{Y}_{\text{com}}) f(\mathbf{y}_{\text{mis}} | \mathbf{y}_{\text{obs}}; \theta^{(k)}) d\mathbf{y}_{\text{mis}}. \end{aligned} \quad (1)$$

Paso M: determinar $\theta^{(k+1)}$ como

$$\theta^{(k+1)} = \arg \max_{\theta} Q(\theta | \theta^{(k)}). \quad (2)$$



Una variante del Algoritmo EM

Dempster, Laird y Rubin (1977) definieron el **Algoritmo EM generalizado (GEM)**, mediante la siguiente modificación del paso M:

*Paso M**: seleccionar $\theta^{(k+1)}$ satisfaciendo,

$$Q(\theta^{(k+1)} | \hat{\theta}^{(k)}) > Q(\theta^{(k)} | \theta^{(k)}).$$

Sugerencia: considerar **sólo un** paso Newton en la optimización de $Q(\theta | \theta^{(k)})$.



Teorema (Dempster, Laird y Rubin, 1977)

Todo algoritmo EM o GEM **incrementa la log-verosimilitud de datos observados** $\ell_o(\boldsymbol{\theta}; \mathbf{Y}_{\text{obs}})$ en cada iteración, esto es,

$$\ell_o(\boldsymbol{\theta}^{(k+1)}; \mathbf{Y}_{\text{obs}}) \geq \ell_o(\boldsymbol{\theta}^{(k)}; \mathbf{Y}_{\text{obs}}).$$

Convergencia (Wu, 1983; Little y Rubin, 1987)

Bajo condiciones suaves, la secuencia $\{\boldsymbol{\theta}^{(k)}\}_{k \geq 0}$ generada por el algoritmo EM (GEM). **Converge a un punto estacionario** de $\ell_o(\boldsymbol{\theta}; \mathbf{Y}_{\text{obs}})$.



Propiedades del algoritmo EM:

- ▶ Frecuentemente el algoritmo EM es **simple**, de **bajo costo** computacional y numéricamente **estable**.
- ▶ Dempster, Laird y Rubin (1977) mostraron que el algoritmo EM converge con **velocidad lineal**, que depende de la **proporción** de información perdida.⁴
- ▶ Para modelos con datos aumentados con densidad en la **familia exponencial**, el algoritmo EM reduce a **actualizar** las estadísticas suficientes.
- ▶ Errores estándar pueden ser obtenidos por cálculo directo, diferenciación numérica o usando el **Principio de Información Perdida** (Louis, 1982).

⁴ puede ser **extremadamente** lento.



Sea Y_1, \dots, Y_n variables aleatorias independientes $\text{SMN}(\mathbf{x}_i\boldsymbol{\beta}, \sigma^2; \mathbf{H})$. Se llevará a cabo la **estimación ML** usando el **algoritmo EM**.

De este modo, tenemos el siguiente **modelo jerárquico**:

$$Y_i|W_i \sim \text{N}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2/\omega_i), \quad W_i \sim \text{H}(\boldsymbol{\delta}), \quad i = 1, \dots, n.$$

En este caso el vector de **datos completos** es $\mathbf{Y}_{\text{com}} = (\mathbf{Y}^\top, \boldsymbol{\omega}^\top)^\top$, donde

$$\mathbf{Y} = (Y_1, \dots, Y_n)^\top, \quad \boldsymbol{\omega} = (\omega_1, \dots, \omega_n)^\top.$$

En este contexto, \mathbf{Y} corresponde a los **datos observados**, mientras que $\boldsymbol{\omega}$ serán asumidos como **datos perdidos**.



Asuma δ conocido, la función de log-verosimilitud de datos completos adopta la forma:

$$\begin{aligned}\ell_c(\boldsymbol{\theta}; \mathbf{y}_{\text{com}}) &= \log f(\mathbf{y}_{\text{com}}; \boldsymbol{\theta}) = \sum_{i=1}^n \log f(y_i, \omega_i; \boldsymbol{\theta}) \\ &= \sum_{i=1}^n \log f(y_i | \omega_i; \boldsymbol{\theta}) + \sum_{i=1}^n \log h(\omega_i; \boldsymbol{\delta}) \\ &= -\frac{n}{2} \log 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n \omega_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 - \frac{1}{2} \sum_{i=1}^n \log \omega_i + \log h^{(n)}(\boldsymbol{\omega}; \boldsymbol{\delta}),\end{aligned}$$

donde $h^{(n)}(\boldsymbol{\omega}; \boldsymbol{\delta})$ denota la densidad conjunta para las variables de mezcla $\boldsymbol{\omega} = (\omega_1, \dots, \omega_n)^\top$.



Estimación ML usando mezclas de escala normal

Considere una estimación para $\theta = \theta^{(k)}$, entonces

$$Q(\theta; \theta^{(k)}) = E\{\ell_c(\theta; \mathbf{y}_{\text{com}}) | \mathbf{y}; \theta^{(k)}\} = Q_1(\beta, \sigma^2; \theta^{(k)}) + Q_2(\delta; \theta^{(k)}),$$

donde

$$Q_1(\beta, \sigma^2; \theta^{(k)}) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \omega_i^{(k)} (Y_i - \mathbf{x}_i^\top \beta)^2,$$

$$Q_2(\delta; \theta^{(k)}) = E\{\log h^{(n)}(\omega; \delta) | \mathbf{y}; \theta^{(k)}\},$$

con $\omega_i^{(k)} = E(\omega_i | \mathbf{x}_i; \theta^{(k)})$ para $i = 1, \dots, n$. En general, la forma para la esperanza condicional requerida en el paso-E del algoritmo EM es dada por:

$$E(\omega_i | \mathbf{x}_i; \theta) = \frac{\int_0^\infty \omega_i^{3/2} \exp(-\omega_i u_i / 2) dH(\delta)}{\int_0^\infty \omega_i^{1/2} \exp(-\omega_i u_i / 2) dH(\delta)},$$

con $u_i = (Y_i - \mathbf{x}_i^\top \beta)^2 / \sigma^2$, $i = 1, \dots, n$.



- **t-Student:** $Y_i \stackrel{\text{ind}}{\sim} t(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$, $i = 1, \dots, n$, en cuyo caso

$$E(\omega_i | Y_i; \boldsymbol{\theta}) = \frac{\nu + 1}{\nu + u_i}.$$

- **Slash:** $Y_i \stackrel{\text{ind}}{\sim} \text{Slash}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \nu)$, para $i = 1, \dots, n$. De este modo,

$$E(\omega_i | Y_i; \boldsymbol{\theta}) = \left(\frac{2\nu + 1}{u_i} \right) \frac{P_1(\nu + 3/2, u_i/2)}{P_1(\nu + 1/2, u_i/2)},$$

donde

$$P_z(a, b) = \frac{b^a}{\Gamma(a)} \int_0^z t^{a-1} e^{-bt} dt,$$

es la función gama incompleta (regularizada).

- **Exponencial Potencia:** $Y_i \stackrel{\text{ind}}{\sim} \text{PE}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2, \lambda)$, $i = 1, \dots, n$, donde

$$E(\omega_i | Y_i; \boldsymbol{\theta}) = \lambda u_i^{\lambda-1}, \quad u_i \neq 0, \lambda \in (0, 1].$$



Estimación ML usando mezclas de escala normal

Finalmente, el algoritmo EM obtener los MLE en el modelo

$$Y_i \stackrel{\text{ind}}{\sim} \text{SMN}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2; \mathbf{H}), \quad i = 1, \dots, n,$$

adopta la forma:

Paso E: para $\boldsymbol{\theta}^{(k)}$, calcular:

$$\omega_i^{(k)} = \mathbb{E}(\omega_i | Y_i; \boldsymbol{\theta}^{(k)}), \quad i = 1, \dots, n.$$

Paso M: actualizar $\boldsymbol{\beta}^{(k+1)}$ y $\sigma^{2(k+1)}$ como:

$$\begin{aligned} \boldsymbol{\beta}^{(k+1)} &= (\mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{Y} \\ \sigma^{2(k+1)} &= \frac{1}{n} (\mathbf{Y} - \mathbf{X} \boldsymbol{\beta}^{(k)})^\top \mathbf{W}^{(k)} (\mathbf{Y} - \mathbf{X} \boldsymbol{\beta}^{(k)}), \end{aligned}$$

donde $\mathbf{W}^{(k)} = \text{diag}(\omega_1(\boldsymbol{\theta}^{(k)}), \dots, \omega_n(\boldsymbol{\theta}^{(k)}))$.

A la convergencia del algoritmo hacemos $\boldsymbol{\beta} = \hat{\boldsymbol{\beta}}$ y $\sigma^2 = \hat{\sigma}^2$.



Llamadas telefónicas en Bélgica 1950-1973

```
# carga datos de llamadas
> library(MASS)
> data(phones)

# carga biblioteca 'heavy'
> library(heavy)

# Ajuste usando distribución Cauchy
> fm <- heavyLm(calls ~ year, data = phones, family = Cauchy())

# Salida
> fm
Call:
heavyLm(formula = calls ~ year, data = phones, family = Cauchy())
Converged in 85 iterations

Coefficients:
(Intercept)          year
   -53.8761         1.1229

Degrees of freedom: 24 total; 22 residual
Scale estimate: 1.394029
```



Llamadas telefónicas en Bélgica 1950-1973

```
# Salida
> summary(fm)
Linear model under heavy-tailed distributions
Data: phones; Family: Cauchy()

Residuals:
    Min       1Q   Median       3Q      Max
-1.848  -0.213   0.319  38.959 188.397

Coefficients:
            Estimate Std. Error Z value  p-value
(Intercept) -53.8761    3.0473  -17.6801   0.0000
year          1.1229    0.0492   22.8051   0.0000

Degrees of freedom: 24 total; 22 residual
Scale estimate: 1.394029
Log-likelihood: -102.28 on 3 degrees of freedom

# 'pesos' estimados
> fm$weights
[1] 0.4694 0.8970 1.9514 1.9051 1.9642 1.6087 1.2597 0.8829 1.5338
[10] 1.8178 2.0000 1.8932 1.8320 0.1381 0.0003 0.0003 0.0002 0.0001
[19] 0.0001 0.0001 0.0083 0.5796 1.9988 1.2589
```



Llamadas telefónicas en Bélgica 1950-1973

```
# Estimando los 'grados de libertad'
> fm <- heavyLm(calls ~ year, data = phones, family = Student(df = 4))
> fm
Call:
heavyLm(formula = calls ~ year, data = phones,
        family = Student(df = 0.35881))
Converged in 170 iterations


Coefficients:
(Intercept)          year
   -54.0142         1.1260

Degrees of freedom: 24 total; 22 residual
Scale estimate: 0.2661921


# 'pesos' estimados
> fm$weights
[1] 0.0791 0.2057 2.9578 2.3797 2.7616 0.7649 0.3692 0.1843 0.6294
[10] 1.3377 3.7112 2.4381 1.9253 0.0197 0.0000 0.0000 0.0000 0.0000
[19] 0.0000 0.0000 0.0011 0.0947 3.6673 0.4728
```



Llamadas telefónicas en Bélgica 1950-1973




(a) normal




(b) Student, $\hat{\nu} = 0.3588$



Llamadas telefónicas en Bélgica 1950-1973



(a) Cauchy



(b) Student, $\hat{\nu} = 0.3588$